# Determinantes Ambientales y Persistencia Temporal en los Brotes de Dengue en Nicaragua (2014–2022)

Emerson Lopez
emerson.zeledon.ni@gmail.com

10 de noviembre de 2026

**Resumen**

Este documento presenta la formulación metodológica, especificación matemática, resultados empíricos y análisis de residuales para el modelamiento de la probabilidad de brotes de dengue en los 18 departamentos de Nicaragua durante el período 2014-2022. Utilizando un Modelo Lineal Mixto Generalizado (GLMM) con distribución binomial y función de enlace logit, se incorporó un intercepto aleatorio departamental y una estructura autorregresiva temporal de primer orden (AR(1)) para aislar la inercia epidémica y evaluar el impacto de variables climáticas (precipitación acumulada y temperatura) y el fenómeno de El Niño. Los resultados muestran una persistencia epidémica semanal extrema ($\rho = 0{,}96$), un efecto multiplicativo dominante de la inercia de casos previos (OR $\approx 16{,}77$ ante duplicación de casos), una asociación positiva de la precipitación acumulada y de la temperatura media, mientras que la anomalía de Niño 3.4 no alcanzó significancia estadística. Un análisis exploratorio de sensibilidad con umbral p90 y rezagos climáticos de 2 a 4 semanas mostró que el bloque climático original mejora el ajuste y la discriminación temporal de forma modesta, mientras que los rezagos específicos no aportan una mejora estable; por tanto, la evidencia respalda un aporte climático condicionado a la inercia epidémica y no un efecto aislado.

# 1. Introducción y Definición del Evento

El dengue constituye una de las arbovirosis de mayor propagación y carga para la salud pública global, afectando primordialmente a regiones tropicales y subtropicales de América Latina y el sudeste asiático (Bhatt et al., 2013). Transmitido predominantemente por hembras infectadas del mosquito *Aedes aegypti*, la dispersión del virus del dengue (DENV, serotipos 1–4) está ligada tanto a factores ecológicos y climáticos como a procesos demográficos y de gestión ambiental urbana (Brady et al., 2012; Morin et al., 2013).

En Nicaragua, el dengue se comporta como una enfermedad endémica e hiperendémica con manifestaciones epidémicas recurrentes de alta intensidad (Gordon et al., 2013). Si bien la transmisión basal persiste durante todo el año, la probabilidad de que un territorio transite hacia una fase epidémica descontrolada depende de la conjunción entre la inercia biológica local (la abundancia de individuos infecciosos y mosquitos activos) y choques hidroclimáticos que expanden los reservorios y aceleran la replicación viral (Anyamba et al., 2019; Suazo-Laguna et al., 2026).

Desde la perspectiva de la vigilancia epidemiológica, modelar el dengue en zonas hiperendémicas presenta desafíos estadísticos notables. Tradicionalmente, la transición hacia una fase de alerta sanitaria no se evalúa únicamente mediante el conteo absoluto de contagios, sino mediante la identificación de umbrales que superan el comportamiento esperado histórico del territorio (Organización Panamericana de la Salud, 2002). En este estudio, se define el evento binario de *brote* ($\text{brote}_{it} = 1$) para el departamento $i$ en la semana epidemiológica $t$ cuando el recuento semanal de casos confirmados supera el percentil 75 empírico calculado sobre toda su serie histórica 2014–2022, sin estratificar por semana epidemiológica. Esta formulación permite estandarizar la alerta independientemente del tamaño poblacional basal de cada región y capturar la probabilidad condicional de que un territorio detone una fase de alarma sanitaria.

El objetivo principal de esta investigación es evaluar el impacto relativo de las precipitaciones acumuladas a corto plazo, la temperatura ambiente y el macroclima modulado por el fenómeno de El Niño sobre la probabilidad de detonar brotes departamentales en Nicaragua durante 2014–2022, aislando la inercia serial.

# 2. Revisión de Literatura

## 2.1. Eco-epidemiología del Dengue y Forzantes Climáticos

La relación entre las fluctuaciones meteorológicas y la dinámica de transmisión de las arbovirosis está respaldada por una amplia base biofísica (Mordecai et al., 2019; Morin et al., 2013). La temperatura ambiente gobierna parámetros vitales de *Aedes aegypti*, tales como la tasa de picadura, la longevidad del mosquito y el período de incubación extrínseca (EIP) del virus, el cual se contrae significativamente en intervalos térmicos cálidos entre 24 °C y 30 °C (Mordecai et al., 2017). No obstante, en ecosistemas de tierras bajas tropicales donde las temperaturas permanecen de forma continua dentro de la ventana permisiva para el virus, la variabilidad de la temperatura semanal suele tener un poder explicativo marginal en comparación con los regímenes de precipitación.

Por su parte, la precipitación pluvial actúa como el forzante hídrico primario al propiciar criaderos para los estadios inmaduros (larvas y pupas) (Bowman et al., 2014). Como han demostrado estudios entomológicos recientes en Nicaragua, la acumulación de recipientes y reservorios de almacenamiento hídrico modula directamente la productividad pupal y la densidad de hembras adultas tanto en sectores urbanos como rurales (Suazo-Laguna et al., 2026). Dado que el ciclo biológico completo (oviposición, desarrollo acuático, emergencia del adulto, ingestión del virus y maduración extrínseca) abarca típicamente entre dos y cuatro semanas, el efecto de

las lluvias sobre los contagios humanos se manifiesta con rezagos acumulados y no como una respuesta contemporánea inmediata (Anyamba et al., 2019; Morin et al., 2013).

A escala sinóptica, las oscilaciones macroclimáticas asociadas al ciclo de El Niño–Oscilación del Sur (ENSO) alteran los patrones pluviométricos y térmicos interanuales en Centroamérica (Anyamba et al., 2019). Las anomalías positivas persistentes de la temperatura superficial del mar en la región Niño 3.4, registradas semanalmente (NOAA Climate Prediction Center, 2026), coinciden frecuentemente con sequías estacionales seguidas de eventos pluviales concentrados o aumentos térmicos anómalos, los cuales favorecen el almacenamiento domiciliario de agua y amplifican el riesgo de epidemias masivas, tal como se registró en la región en 2015–2016 y 2019.

### 2.2. Evidencia Epidemiológica Previa en Nicaragua

La epidemiología del dengue en Nicaragua ha sido objeto de investigaciones longitudinales exhaustivas, primordialmente a través del Estudio de la Cohorte Pediátrica de Dengue (PDCS) en Managua (Gordon et al., 2013; Standish et al., 2010). Dichos estudios han documentado la circulación alternante de serotipos virales, la dinámica de transmisión sintomática frente a infecciones inaparentes y la alta eficiencia en la captación de casos dentro del sistema de vigilancia (Standish et al., 2010). Asimismo, estudios locales sobre la distribución de *Aedes aegypti* en distritos de Managua demuestran que las poblaciones del vector persisten con elevadas densidades a lo largo de las estaciones seca y lluviosa, amplificadas por prácticas de almacenamiento de agua (Suazo-Laguna et al., 2026).

A pesar de este sólido cuerpo de literatura biomédica y entomológica, la mayor parte de las investigaciones empíricas nicaragüenses se han concentrado a escala comunitaria o distrital en la capital (Managua). Existe una brecha en la evaluación inferencial multianual que abarque la totalidad de los 18 departamentos y regiones autónomas bajo un diseño de datos de panel, controlando explícitamente tanto la heterogeneidad espacial como la extrema persistencia autorregresiva de la vigilancia semanal.

### 2.3. Consideraciones Metodológicas y Dependencia Serial

El modelado estadístico de series temporales de vigilancia epidemiológica en paneles geográficos exige abordar dos retos econométricos esenciales: la heterogeneidad estructural no observada entre regiones y la fuerte autocorrelación temporal (Zuur et al., 2010). Ignorar la dependencia serial conduce a estimaciones artificialmente precisas de los errores estándar y genera significancia espuria en las covariables climáticas exógenas.

La integración de Modelos Lineales Mixtos Generalizados (GLMM) con enlace logit (Breslow & Clayton, 1993; Pinheiro & Bates, 2000) y procesos autorregresivos de primer orden (AR(1)) en las componentes estocásticas permite disociar la inercia interna del brote respecto a los choques climáticos exógenos (Diggle et al., 2002). Al formular el modelo con propósitos confirmatorios e inferenciales guiados por la eco-epidemiología y no por minería algorítmica de especificaciones (*data dredging*) (Shmueli, 2010), se garantiza una interpretación robusta de las razones de momios asociadas al riesgo de brote.

## 3. Metodología

La especificación del modelo se definió *a priori* con base en la literatura eco-epidemiológica sobre determinantes del dengue (Anyamba et al., 2019; Mordecai et al., 2019) y en la estructura jerárquica del panel longitudinal. La inclusión del intercepto aleatorio departamental responde a la necesidad de controlar la heterogeneidad estructural no observada entre regiones, mientras que la estructura AR(1) se incorporó para mitigar la dependencia serial inherente a las series semanales de vigilancia epidemiológica (Zuur et al., 2010). Asimismo, las covariables climáticas

se seleccionaron por su asociación biofísica documentada con el ciclo del vector. No se realizó una búsqueda exhaustiva de especificaciones alternativas para construir el modelo principal (como selección paso a paso o *data dredging*), dado que el objetivo primordial del estudio es inferencial y confirmatorio, y no predictivo (Shmueli, 2010). Sin embargo, como análisis de sensibilidad exploratorio *post hoc*, se evaluaron un umbral alternativo p90, rezagos climáticos de 2 a 4 semanas y una validación temporal 2014–2019/2020–2022; estos análisis se reportan en la Sección 5.3 y no se utilizaron para seleccionar la especificación principal. El reporte de este estudio sigue las directrices STROBE (von Elm et al., 2007) y RECORD (Benchimol et al., 2015) para estudios observacionales y de datos rutinarios.

### 3.1. Datos

Los registros epidemiológicos provienen de la plataforma global OpenDengue (Clarke et al., 2025), que en esta extracción reporta únicamente casos confirmados a escala semanal y por departamento, sin distinguir entre casos probables, clínicos o graves. Se retuvieron las observaciones con resolución temporal semanal (`T_res = "Week"`) y granularidad administrativa de primer nivel (`adm_1_name`), lo que arroja un panel de 18 departamentos/regiones autónomas observados semanalmente. La serie cruda abarca desde el 5 de enero de 2014 hasta el 6 de noviembre de 2022. Tras construir los rezagos y la precipitación acumulada de tres semanas, la muestra de modelado comprende 8.280 registros semanales (460 semanas por departamento) desde el 19 de enero de 2014 hasta el 6 de noviembre de 2022. Las coordenadas geográficas de referencia para cada unidad territorial se presentan en la Tabla 1.

Tabla 1: Departamentos de Nicaragua y coordenadas geográficas de referencia

| **Departamento / Región** | **Latitud (°N)** | **Longitud (°O)** |
|---|---|---|
| BILWI | 14.0351 | -83.3888 |
| BOACO | 12.4722 | -85.6586 |
| CARAZO | 11.8540 | -86.2000 |
| CHINANDEGA | 12.6294 | -87.1311 |
| CHONTALES | 12.1063 | -85.3645 |
| ESTELI | 13.0918 | -86.3538 |
| GRANADA | 11.9299 | -85.9560 |
| JINOTEGA | 13.0988 | -86.0022 |
| LEON | 12.4379 | -86.8780 |
| MADRIZ | 13.4667 | -86.5833 |
| MANAGUA | 12.1364 | -86.2514 |
| MASAYA | 11.9744 | -86.0942 |
| MATAGALPA | 12.9256 | -85.9175 |
| NUEVA SEGOVIA | 13.6333 | -86.4833 |
| REGION AUTONOMA DEL ATLANTICO SUR | 12.0137 | -83.7635 |
| RIO SAN JUAN | 11.1097 | -84.7797 |
| RIVAS | 11.4372 | -85.8263 |
| ZELAYA CENTRAL | 12.0000 | -84.2833 |

A partir de las coordenadas departamentales (Tabla 1), se extrajeron las series climáticas de temperatura media y precipitación acumulada diaria con la API histórica de Open-Meteo (2024)[1], se agregaron a escala semanal tomando la media para temperatura y la suma para precipitación. El índice temporal semanal (`tiempo_factor`) se definió como la fecha de inicio de cada semana epidemiológica (domingo), construida con `lubridate::floor_date(..., unit = "week", week_start = 7)`. La precipitación acumulada de tres semanas (`Rain_acc3`) se calculó como una suma móvil alineada a la derecha (`RcppRoll::roll_sum`).

[1]Para la Región Autónoma del Atlántico Sur se tomaron las coordenadas de Bluefields; para Río San Juan, las de San Carlos; y para Zelaya Central, las del municipio de El Rama.

La variable explicada corresponde al evento binario de brote$_{it}$, definida como 1 en aquellas semanas epidemiológicas donde la incidencia superó el percentil 75 empírico calculado dentro de cada departamento sobre toda su serie 2014–2022 y no dentro de cada semana epidemiológica, siguiendo el criterio de canal endémico establecido por la Organización Panamericana de la Salud (2002). El umbral se redondeó hacia abajo al entero más cercano con `floor()` para respetar la naturaleza discreta de `dengue_total`. La anomalía macroclimática de El Niño se incorporó como la media móvil de 12 semanas de la anomalía de la temperatura superficial del mar en la región Niño 3.4 (`nino34_12s`), construida a partir de los índices semanales OISST v2.1 del NOAA Climate Prediction Center (2026), con período base 1991–2020. La misma serie `nino34_12s` se utilizó en todas las estimaciones, incluidas las Tablas 2 y 3. El resto de covariables son la precipitación acumulada de tres semanas (`Rain_acc3`), la temperatura media semanal (`Temperature`), la inercia epidémica capturada mediante el logaritmo natural de los casos de la semana anterior más uno, $\ln(\text{casos}_{t-1} + 1)$, denotado `ln_casos_semana_anterior`, y controles temporales de estacionalidad mensual (`mes`) y tendencia anual (`year`).

El panel crudo presentó 36 departamento-semanas sin registro (0,4 % del panel completo de 8.316). Para mantener una serie semanal regular, la grilla se completó con la función `fill_gaps()` de `tsibble` y `dengue_total` se imputó mediante interpolación lineal dentro de cada departamento con la función `na_interpolation(..., option = "linear")` de `imputeTS`; las brechas residuales de temperatura y lluvia semanal también se interpolaron linealmente dentro del departamento. La imputación supone transiciones suaves y datos faltantes no informativos, y no propaga la incertidumbre de imputación a los errores estándar ni a los intervalos de confianza.

Todos los análisis se realizaron en R con paquetes instalados desde un snapshot de Posit Package Manager con fecha 2026-09-16. Los paquetes clave empleados fueron `glmmTMB`, `DHARMa`, `performance`, `ggeffects`, `broom.mixed`, `tsibble`, `imputeTS` y `RcppRoll`.

Para modelar la probabilidad de brote controlando simultáneamente la heterogeneidad no observada entre departamentos y la dependencia serial, se formuló un Modelo Lineal Mixto Generalizado (GLMM) con función de enlace logit (Breslow & Clayton, 1993; Pinheiro & Bates, 2000) implementado mediante la librería `glmmTMB` (Brooks et al., 2017) en R:

```
modelo_1 <- glmmTMB(
brote ~
nino34_12s +
Rain_acc3 +
Temperature +
ln_casos_semana_anterior +
mes +                    #estacionalidad mensual
year +                   #tendencia anual
(1 | DEPARTAMENTO) +  #intercepto aleatorio departamental
ar1(tiempo_factor + 0 | DEPARTAMENTO), #inercia temporal AR
    (1)
family = binomial(link = "logit"),
data = dengue_etapa1
)
```

## 4. Especificación Matemática

El modelo combina una regresión logística para el evento binario de brote con un intercepto aleatorio departamental y una matriz de correlación temporal.

### 4.1. Componente Aleatorio y Función de Enlace

Dado que la variable de respuesta brote es binaria (0 = No hay brote, 1 = Sí hay brote), el modelo asume que el evento $Y_{it}$ (para el departamento $i$ en la semana $t$) sigue una distribución de la familia Binomial[2] (McCullagh & Nelder, 1989):

$$Y_{it} \sim \text{Binomial}(1, p_{it}) \tag{1}$$

Para proyectar la probabilidad esperada de brote ($p_{it}$) en la escala real sin arrojar estimaciones fuera del intervalo $[0, 1]$, se utiliza la función de enlace Logit:

$$\text{logit}(p_{it}) = \ln\left(\frac{p_{it}}{1 - p_{it}}\right) = \eta_{it} \tag{2}$$

### 4.2. Predictor Lineal ($\eta_{it}$)

La ecuación completa del modelo, que proyecta el riesgo combinando el clima y la inercia epidemiológica, se define como:

$$\begin{aligned}\text{logit}(p_{it}) = \beta_0 + \beta_1 \text{nino34_12s}_{it} + \beta_2 \text{Rain_acc3}_{it} + \beta_3 \text{Temperature}_{it} \\ + \beta_4 \ln_\text{casos_semana_anterior}_{it} + \sum_{m=2}^{12} \gamma_m \text{mes}_{m,it} + \sum_{y=2015}^{2022} \delta_y \text{year}_{y,it} + u_i + \omega_{it}\end{aligned} \tag{3}$$

### 4.3. Parámetros y Estructura Jerárquica

El modelo desglosa sus componentes estocásticos y sistemáticos de la siguiente forma:

- **Efectos Fijos ($\beta$):**
  - $\beta_0$: Intercepto global del modelo. Es el nivel basal de riesgo de brote (en escala log-odds) que sirve como punto de partida común a todos los departamentos, antes de incorporar el efecto del clima, la inercia epidémica y la desviación propia de cada departamento $u_i$. En términos prácticos, corresponde al riesgo log-odds esperado cuando todas las covariables valen cero y $u_i = 0$.
  - $\beta_1, \beta_2, \beta_3$: Coeficientes[3] lineales cuyos valores exponenciados (OR = $e^{\beta}$) representan la razón de momios (*Odds Ratio*) asociada a la anomalía de Niño 3.4 (promedio móvil de 12 semanas), a cada milímetro adicional de precipitación acumulada de tres semanas y a cada grado Celsius de temperatura media.
  - $\beta_4$: Coeficiente paramétrico de la inercia epidémica rezagada en escala logarítmica, donde el impacto multiplicativo sobre los *odds* ante un incremento por factor $k$ en los casos previos se evalúa mediante $k^{\beta_4}$ (por ejemplo, $2^{\beta_4}$ para una duplicación de casos).
  - $\gamma_m, \delta_y$: Coeficientes de los controles fijos de estacionalidad mensual y tendencia anual, incluidos para absorber la variación temporal de largo plazo y evitar que el clima reciba una parte de la persistencia epidémica.

[2] Dado que cada fila del panel evalúa la presencia o ausencia del evento como un desenlace binario (1 = brote, 0 = no brote), el modelo estima la probabilidad semanal condicional del evento ($p_{it}$), cuya varianza depende de dicha probabilidad según la relación $p_{it}(1 - p_{it})$.

[3] Los coeficientes $\beta$ (efectos fijos) se estiman a partir de los datos maximizando la verosimilitud (en términos intuitivos, el algoritmo busca los valores de $\beta$ que mejor explican los brotes observados en los 8,280 registros del panel) del modelo. En concreto, `glmmTMB` (Brooks et al., 2017) aproxima la integral de la verosimilitud marginal mediante la aproximación de Laplace y obtiene los valores de $\beta$ que hacen más probables las observaciones registradas, dados los efectos aleatorios. Cada $\beta$ viene acompañado de un error estándar y un valor $z$, con los que se construyen los intervalos de confianza y las pruebas de significancia reportadas en la Tabla 2.

- **Intercepto Aleatorio Departamental ($u_i$):**

$$u_i \sim \mathcal{N}(0, \sigma_u^2), \qquad i = 1, \ldots, 18. \tag{4}$$

Captura la heterogeneidad no observada entre los 18 departamentos, permitiendo que cada región posea su propio nivel basal de riesgo endémico.

Este término corresponde a un intercepto aleatorio por departamento o región autónoma (Fitzmaurice et al., 2011) (`(1 | DEPARTAMENTO)`). No se estima una varianza independiente para cada departamento, sino una única varianza común $\sigma_u^2$ que describe cuán dispersos están los niveles basales de riesgo log-odds de los 18 departamentos alrededor del intercepto global $\beta_0$. Así, el intercepto efectivo del departamento $i$ es $\beta_0 + u_i$. Este componente modela diferencias departamentales no observadas.

- **Efecto Aleatorio Temporal AR(1) ($\omega_{it}$):** Para controlar la dependencia temporal serial dentro de cada unidad geográfica (`ar1(tiempo_factor + 0 | DEPARTAMENTO)`), se incorpora un efecto aleatorio $\omega_{it}$ que varía semana a semana dentro de cada departamento y que captura toda la persistencia temporal no explicada por las covariables. Para cada departamento $i$, el vector de estos efectos a lo largo de las $T$ semanas, $\boldsymbol{\omega}_i = (\omega_{i1}, \ldots, \omega_{iT})^\top$, se modela como un proceso gaussiano con media cero y estructura de covarianza autorregresiva de primer orden (Diggle et al., 2002):

$$\mathrm{Cov}(\omega_{it}, \omega_{is}) = \sigma_\omega^2 \rho^{|t-s|}. \tag{5}$$

Los dos parámetros que gobiernan esta estructura tienen una interpretación directa:

  - $\sigma_\omega^2$: varianza del efecto temporal. Mide la magnitud típica de las fluctuaciones aleatorias que experimenta la probabilidad de brote semana a semana en un mismo departamento, una vez descontado el efecto de las covariables y del intercepto departamental. Un valor grande indica que existen factores temporales no observados que mueven el riesgo de manera sustancial.
  - $\rho$: coeficiente de autocorrelación de primer orden. Mide cuán parecido es el efecto de una semana con el de la semana inmediatamente anterior. Sus valores están acotados entre $-1$ y 1; un $\rho$ cercano a 1 implica que la serie temporal del riesgo es muy persistente (lo que ocurre esta semana se parece mucho a lo que ocurrió la semana pasada), mientras que un $\rho$ cercano a 0 implica que la memoria se disipa rápido.

La expresión $\rho^{|t-s|}$ cuantifica la correlación entre dos semanas cualesquiera separadas por $|t - s|$ pasos (Box et al., 2015). Por ejemplo, si $\rho = 0.96$, la correlación entre semanas contiguas ($|t-s| = 1$) es 0.96; entre semanas separadas por dos períodos es $0.96^2 \approx 0.92$; y decae de forma exponencial conforme aumenta la distancia temporal. La forma gaussiana del proceso implica que, para cada departamento, $\omega_{it}$ sigue una distribución normal con varianza constante $\sigma_\omega^2$ y correlación decreciente con el tiempo.

En términos sustantivos, este componente permite distinguir el efecto genuino de las covariables climáticas del simple arrastre epidémico que se hereda de una semana a otra. Sin él, el modelo atribuiría al clima una parte de la persistencia que en realidad es inercia interna del brote, inflando artificialmente la significancia de variables como la precipitación. La evidencia empírica de un $\rho = 0.96$ (Tabla 2) confirma que la probabilidad de brote en un departamento está fuertemente condicionada por su estado en la semana anterior.

Tabla 2: Resultados del Modelo GLMM Binomial con Inercia AR(1)

| **Efectos Fijos** | **Estimación ($\beta$)** | **Error Est.** | $z$ | **Valor $p$** |
|---|---|---|---|---|
| (Intercepto) | $-24.456$ | 2.110 | $-11.59$ | $< 0.001$ |
| Anomalía Niño 3.4 (12 sem) | 0.132 | 0.117 | 1.14 | 0.256 |
| Precipitación acum. (`Rain_acc3`) | 0.00239 | $< 0.001$ | 3.32 | $< 0.001$ |
| Temperatura (`Temperature`) | 0.240 | 0.078 | 3.08 | 0.002 |
| Casos previos (`ln_casos_semana_anterior`) | 4.068 | 0.160 | 25.47 | $< 0.001$ |
| **Efectos Aleatorios** | **Varianza** | **Desv. Est.** | **Parámetro** | |
| Intercepto por Departamento ($\sigma_u^2$) | 5.429 | 2.330 | - | |
| Efecto temporal AR(1) ($\sigma_\omega^2$) | 0.912 | 0.955 | $\rho = 0.96$ | |
| **Bondad de Ajuste:** AIC = 3602.8 | BIC = 3792.3 | Obs = 8280 | Grupos = 18 | |

# 5. Resultados

## 5.1. Estimaciones del Modelo y Odds Ratios

Además de estos efectos, el modelo incluye controles fijos de mes y año para absorber estacionalidad y tendencia; sus coeficientes se omiten de la tabla por espacio.

Los resultados de la estimación del modelo de brote se resumen en la Tabla 3.

Tabla 3: Razones de momios del modelo

| Variable | Cambio en Odds ( %) |
|---|---|
| (Intercepto) | - |
| El Niño (anomalía 12 sem) | +14.1 % |
| Precipitación acum. 3 sem | +0.24 % por mm |
| Temperatura media | +27.1 % |
| Log-casos semana anterior | $2^{4.068} \approx 16.77\times$ |

La precipitación acumulada y la temperatura media resultaron estadísticamente significativas al 5 %, mientras que la anomalía de Niño 3.4 no alcanzó significancia (p=0.256). El efecto térmico positivo es consistente con la eco-epidemiología de zonas tropicales bajas: dentro de la ventana térmica permisiva para el vector (aproximadamente 24–30 °C), incrementos en la temperatura media semanal se asocian con una mayor probabilidad de brote (Mordecai et al., 2017).

En cuanto a la anomalía de Niño 3.4, el odds ratio estimado es 1.141 (IC 95 %: 0.908 a 1.434; p=0.256), manteniendo las demás variables constantes. Al excluir la tendencia anual, el OR asciende a 1.20 (IC 95 %: 0.987 a 1.46; p=0.067), lo que sugiere que su señal es frágil y se solapa con la variación macroclimática de largo plazo.[4]

Para la variable de inercia epidémica (`ln_casos_semana_anterior`), el coeficiente $\beta = 4.068$ indica un riesgo multiplicativo masivo. Evaluando un factor de duplicación de casos respecto a la semana anterior mediante la fórmula $\text{OR} = (\text{factor})^{\beta}$:

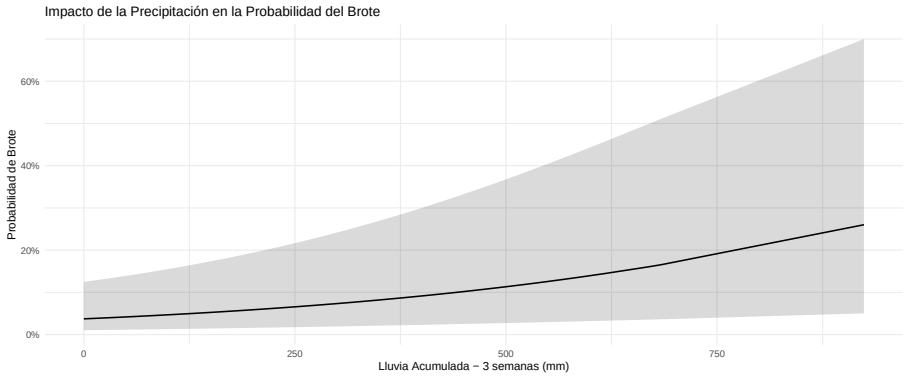
$$\text{OR} = 2^{4.068} \approx 16.77 \tag{6}$$

Es decir, duplicar los casos de la semana previa se asocia con un aumento de aproximadamente 16.77 veces en los odds de desencadenar un brote (IC 95 %: 13.50 a 20.83). La estructura temporal

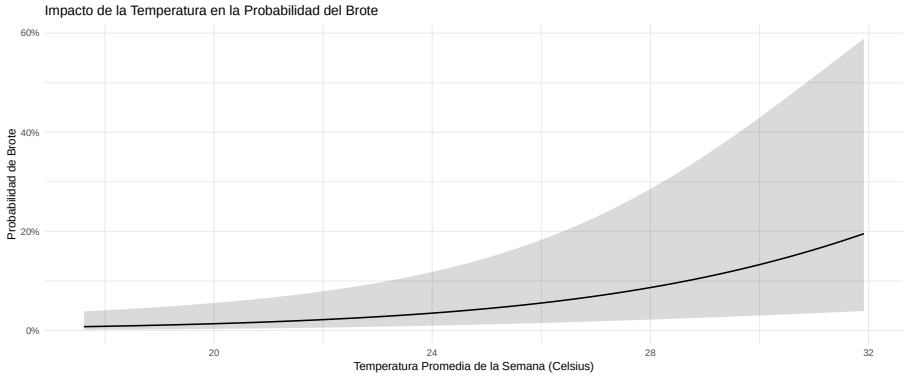
[4]Los intervalos de confianza al 95 % para las razones de momios se obtuvieron mediante el método de Wald, transformando los límites del intervalo de confianza del coeficiente $\beta$ en escala log-odds: $\text{IC}_{95\,\%}(\text{OR}) = \exp\left(\hat{\beta} \pm 1.96 \cdot \text{EE}(\hat{\beta})\right)$. Para la anomalía de Niño 3.4, con $\hat{\beta} = 0.132$ y EE = 0.117, se obtiene $\exp(0.132 \pm 1.96 \cdot 0.117) = \exp(-0.097, 0.361) = (0.908, 1.435)$, lo que equivale a un cambio porcentual entre $-9.2$ % y $+43.5$ %. El mismo procedimiento se aplicó al resto de las covariables.

reveló un parámetro autorregresivo $\rho = 0.96$. Esto indica que la incidencia semanal hereda casi la totalidad del comportamiento inmediato anterior dentro del mismo departamento.

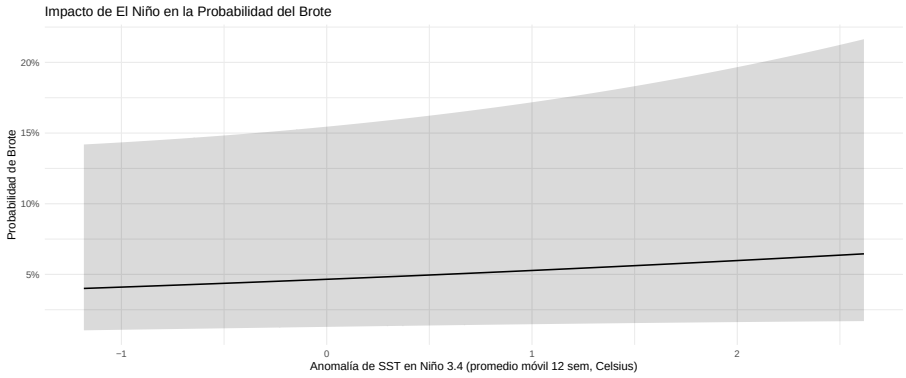
## 5.2. Análisis Gráfico de Efectos




(a) Precipitación acumulada




(b) Temperatura media




(c) Anomalía de Niño 3.4

Figura 1: Efectos marginales de la precipitación acumulada, la temperatura y la anomalía de Niño 3.4.

Como se observa en la Figura 1, la probabilidad de brote aumenta con la precipitación acumulada y con la temperatura media. En el panel superior, la relación con la precipitación es no lineal: el efecto es más pronunciado en el tramo inicial y la banda de confianza se amplía hacia valores extremos. En el panel central, el efecto de la temperatura es positivo y más lineal. En el panel inferior, la curva de Niño 3.4 es casi plana y la banda de confianza es amplia, lo que refleja la falta de una asociación independiente robusta.

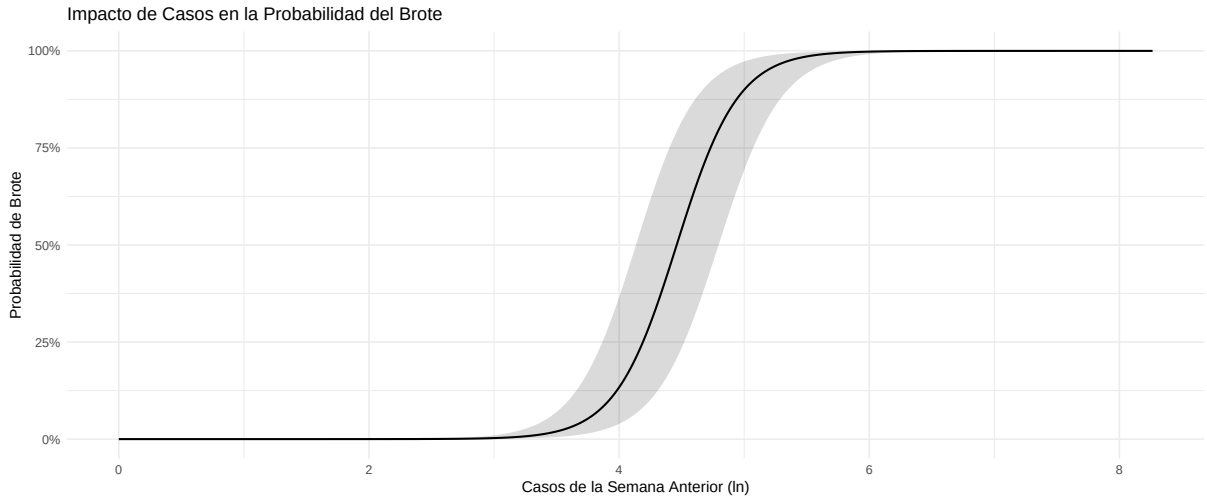



Figura 2: Efecto de Casos de la Semana Anterior

Por su parte, la Figura 2 muestra un marcado umbral de quiebre: con casos rezagados por debajo de 3.5 en escala logarítmica, la probabilidad de brote es cercana al 0 %. Entre los valores 4 y 5, la curva experimenta una pendiente casi vertical, disparando la probabilidad hasta saturarse al 100 % cuando se superan los 6 puntos logarítmicos.

### 5.3. Análisis de Sensibilidad: Umbral p90, Rezagos Climáticos y Validación Temporal

Como análisis exploratorio *post hoc*, se evaluó la robustez del modelo ante dos decisiones de especificación: el umbral que define el brote y la forma de incorporar el clima. Se compararon los umbrales p75 y p90, y para cada uno se ajustaron tres modelos logit: uno solo con inercia, uno con las covariables climáticas originales (`nino34_12s`, `Rain_acc3` y `Temperature`) y uno con rezagos separados de lluvia y temperatura en las semanas $t-2$, $t-3$ y $t-4$. Todos los modelos conservaron la inercia epidémica, la estacionalidad mensual, el intercepto aleatorio departamental y la estructura AR(1).

Para estabilizar la estimación y permitir la validación temporal, en esta sección se reemplazó el factor año por una tendencia anual lineal centrada en 2014 (`year_num`); por esa razón, los valores de AIC no son directamente comparables con la Tabla 2. Además, al construir los rezagos se perdieron tres semanas por departamento, de modo que la muestra común de esta sensibilidad es de 8.208 departamento-semanas: 2.047 brotes con p75 (24,9 %) y 821 con p90 (10,0 %).

Tabla 4: Comparación de modelos de sensibilidad con umbral p75 y p90

| **Modelo** | **AIC** | **ΔAIC** | **AUC poblacional** | **ΔAUC** |
|---|---|---|---|---|
| p75 solo inercia | 3646,9 | 0,0 | 0,892 | 0,0 |
| p75 clima original | 3632,1 | 14,8 | 0,890 | −0,0015 |
| p75 clima con rezagos 2–4 | 3640,9 | 6,0 | 0,894 | +0,0021 |
| p90 solo inercia | 1963,8 | 0,0 | 0,923 | 0,0 |
| p90 clima original | 1791,7 | 172,1 | 0,917 | −0,0059 |
| p90 clima con rezagos 2–4 | 1377,4 | 586,4 | 0,912 | −0,0105 |

**Nota:** ΔAIC y ΔAUC se calculan contra el modelo solo inercia del mismo umbral.

En el umbral p75, el clima original mejoró el AIC en 14,8 puntos ($\chi^2 = 20{,}82$ con 3 grados de libertad; $p < 0{,}001$), pero no aumentó la AUC poblacional. Añadir rezagos tampoco mejoró el ajuste respecto al clima original ($\chi^2 = 0{,}00$ con 4 grados de libertad; $p = 1{,}000$). En el

umbral p90, el clima original redujo el AIC en 172,1 puntos ($\chi^2 = 178{,}14$ con 3 grados de libertad; $p < 0{,}001$), mientras que el modelo con rezagos mostró una reducción mucho mayor ($\Delta\text{AIC} = 586{,}4$; $\chi^2 = 422{,}23$ con 4 grados de libertad; $p < 0{,}001$).

Ese último valor requiere cautela. Los modelos p90 presentaron coeficientes máximos de 204 y 933 en escala log-odds para el clima original y con rezagos, respectivamente. La función `diagnose()` de `glmmTMB` advirtió separación casi completa en ambos. Por tanto, el *log-likelihood* del modelo p90 con rezagos está inflado por una casi-separación y no debe interpretarse como evidencia de un mejor mecanismo climático. La Tabla 5 ayuda a separar el ajuste interno de la capacidad de discriminación fuera de muestra.

Tabla 5: Validación temporal: entrenamiento 2014–2019 y prueba 2020–2022

| **Modelo** | **AUC 2014–2019** | **AUC 2020–2022** | **ΔAUC prueba** |
|---|---|---|---|
| p75 solo inercia | 0,900 | 0,869 | 0,0 |
| p75 clima original | 0,897 | 0,869 | +0,0002 |
| p75 clima con rezagos 2–4 | 0,901 | 0,873 | +0,0039 |
| p90 solo inercia | 0,921 | 0,936 | 0,0 |
| p90 clima original | 0,921 | 0,944 | +0,0082 |
| p90 clima con rezagos 2–4 | 0,908 | 0,935 | −0,0007 |

**Nota:** el modelo p90 con rezagos no alcanzó una Hessiana definida en la validación.

La validación temporal mostró que el clima original en p90 fue el único bloque que mejoró de forma apreciable la discriminación fuera de muestra (AUC 0,944 frente a 0,936 con inercia sola; $\Delta\text{AUC} = +0{,}0082$). En p75, los rezagos produjeron una mejora mínima ($\Delta\text{AUC} = +0{,}0039$) y el clima original no mejoró la AUC de prueba. En p90, el modelo con rezagos no superó a la inercia ($\Delta\text{AUC} = -0{,}0007$) y además no convergió a una Hessiana definida. En conjunto, la evidencia favorece un aporte modesto del bloque climático original, pero no permite sostener que los rezagos de 2 a 4 semanas añadan información estable.

Tabla 6: Razones de momios de los rezagos climáticos de 2 a 4 semanas

| **Rezago** | **p75: OR (IC 95 %)** | **p90: OR (IC 95 %)** |
|---|---|---|
| Lluvia $t-2$ | 1,00 (1,00–1,01) | 1,05 (0,94–1,17) |
| Lluvia $t-3$ | 1,00 (1,00–1,01) | 0,902 (0,862–0,944) |
| Lluvia $t-4$ | 0,999 (0,996–1,00) | 0,940 (0,907–0,976) |
| Temperatura $t-2$ | 0,990 (0,820–1,19) | 114 (0,37–35111) |
| Temperatura $t-3$ | 1,15 (0,937–1,42) | 121 (3,73–3909) |
| Temperatura $t-4$ | 0,925 (0,769–1,11) | 0,926 (0,001–780) |

**Nota:** en p75 los OR son estables y cercanos a la nulidad; en p90 los intervalos de temperatura reflejan casi-separación.

Los OR de la Tabla 6 confirman esa lectura. En el modelo p75, estable, todos los rezagos de lluvia y temperatura son cercanos a la nulidad, con intervalos estrechos. En p90, los rezagos de lluvia $t-3$ y $t-4$ sugieren odds menores, pero sus estimaciones provienen de un modelo con casi-separación, igual que los intervalos de temperatura, que abarcan varios órdenes de magnitud. Por ello, no se interpretan como efectos específicos de rezago.

En síntesis, el análisis de sensibilidad sostiene que el bloque climático original aporta información medible sobre la probabilidad de brote, especialmente en el umbral p90 y en la validación temporal, pero no permite afirmar que los rezagos de 2 a 4 semanas mejoren de forma estable al modelo ni que el clima actúe como un efecto aislado de la inercia epidémica.

# 6. Residuales y Diagnóstico del Modelo

Tabla 7: Diagnóstico de Multicolinealidad (VIF y Tolerancia)

| Covariable | VIF | IC 95 % VIF | VIF Aj. | Tolerancia | IC 95 % Tol. |
|---|---|---|---|---|---|
| Niño 3.4 (12 sem) | 1.65 | [1.60, 1.70] | 1.28 | 0.61 | [0.59, 0.62] |
| Precipitación acum. | 2.19 | [2.12, 2.27] | 1.48 | 0.46 | [0.44, 0.47] |
| Temperatura | 2.15 | [2.09, 2.23] | 1.47 | 0.46 | [0.45, 0.48] |
| Casos previos | 1.26 | [1.23, 1.29] | 1.12 | 0.80 | [0.77, 0.82] |
| Mes | 4.65 | [4.47, 4.83] | 2.16 | 0.22 | [0.21, 0.22] |
| Año | 2.17 | [2.10, 2.24] | 1.47 | 0.46 | [0.45, 0.48] |

La evaluación de colinealidad mediante los factores de inflación de varianza (VIF) arrojó valores de hasta 4.65 para las covariables. El VIF más alto corresponde a mes (4.65), seguido de año (2.17), ambos por debajo del umbral convencional de 5; los VIF ajustados se mantienen por debajo de 2.2, descartando problemas de multicolinealidad.

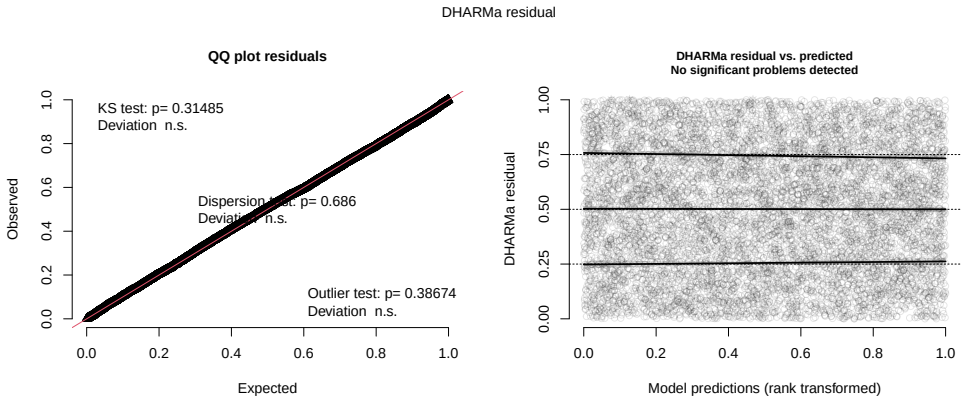



Figura 3: Diagnóstico de residuales mediante simulación DHARMa.

Para validar los supuestos distribucionales y la ausencia de sobredispersión, se aplicó la prueba de simulación de residuales vía `DHARMa` (Hartig, 2022) (Figura 3). Los residuales pasan las pruebas de no desviación significativa ($p = 0.31$), no sobredispersión ($p = 0.69$) y ausencia de valores atípicos ($p = 0.387$), manteniendo cuantiles alineados.

Adicionalmente, la evaluación de autocorrelación temporal sobre los residuales agrupados por fecha de inicio mediante la prueba de Durbin-Watson arrojó un estadístico DW = 1.8589 con un valor $p = 0.1294$, por lo que no se detectó autocorrelación temporal remanente. Cabe precisar que la prueba de Durbin-Watson evalúa dependencia temporal, no autocorrelación espacial.

# 7. Discusión

El modelo principal mostró un ajuste adecuado al superar las pruebas de simulación de residuales, sobredispersión y autocorrelación temporal. El análisis exploratorio de sensibilidad evaluó un umbral alternativo p90 y rezagos climáticos de 2 a 4 semanas. Los resultados indican que el bloque climático original aporta información medible, sobre todo en el umbral p90 y en la validación temporal, pero que los rezagos específicos no mejoran de forma estable al modelo y que los modelos p90 con rezagos presentan casi-separación. Por tanto, la calibración del umbral sigue siendo una línea de trabajo futura, pero ya no como una hipótesis sin explorar: el umbral

p90 se evaluó y no alteró la conclusión central de que la inercia epidémica domina la probabilidad de brote.

Con fines de transparencia metodológica, cabe señalar que durante la fase exploratoria se intentó modelar directamente el recuento continuo de casos de dengue, evaluando los periodos de mayor intensidad epidémica mediante datos filtrados y truncados. Dicha aproximación fue descartada al no alcanzar la robustez estadística: el modelo basado en la distribución binomial negativa truncada presentó desviaciones severas y desalineación en los cuantiles de los residuales simulados vía `DHARMa`, incluso tras explorar diferentes transformaciones de escala. Por esta razón, se priorizó la especificación binaria del evento de brote, que ofrece estabilidad numérica, control de errores y una interpretación directa del riesgo de transición hacia fases epidémicas. Futuros trabajos interesados en el modelado continuo durante fases epidémicas agudas pueden retomar esta línea partiendo de las implementaciones alternativas disponibles en el repositorio del proyecto, pero deberán enfrentar el desafío de estabilizar numéricamente la componente de conteo sobre paneles de alta variabilidad departamental.

## 8. Limitaciones

Este estudio tiene varias limitaciones que condicionan la interpretación de los resultados. Primero, el diseño es observacional y ecológico, con datos agregados a escala departamental y semanal; por tanto, las asociaciones estimadas no identifican relaciones causales ni efectos a nivel individual. Además, la variable de desenlace clasifica cada semana como brote o no brote a partir del percentil 75 interno de cada departamento, un umbral operativo útil para comparar riesgo relativo pero no validado contra un estándar clínico o de salud pública. En el análisis de sensibilidad se evaluó además el percentil 90, que redujo la frecuencia de brotes a 10,0 % y no modificó la conclusión central, pero tampoco constituye un estándar validado. Como ambos umbrales se calculan sobre toda la serie 2014–2022, no capturan cambios en la definición de brote ni en la capacidad de vigilancia a lo largo del tiempo.

Segundo, la serie de casos proviene de OpenDengue y puede estar afectada por subregistro, cambios en la notificación y heterogeneidad en la calidad del dato entre departamentos. Tampoco se dispone de información sobre serotipo, edad, intervenciones de control vectorial, movilidad poblacional u otras covariables que podrían confundir las asociaciones climáticas. La estructura espacial se limita a un intercepto aleatorio departamental; no se modeló autocorrelación espacial formal ni dependencia entre departamentos vecinos.

Tercero, el panel presentó 36 departamento-semanas sin registro (0,4 % del panel completo de 8.316). La grilla se completó con la función `fill_gaps()` de `tsibble` y los casos se imputaron mediante interpolación lineal dentro de cada departamento con la función `na_interpolation(..., option = "linear")` de `imputeTS`; las brechas residuales de temperatura y lluvia también se interpolaron linealmente dentro del departamento. Este procedimiento supone transiciones suaves y datos faltantes no informativos, y no propaga la incertidumbre de imputación a los errores estándar ni a los intervalos de confianza.

Cuarto, la inercia epidémica de la semana anterior absorbe gran parte de la señal explicativa. El modelo de sensibilidad sin `ln_casos_semana_anterior` mostró separación casi completa: el coeficiente máximo absoluto fue 67,8 y el OR de Niño 3.4 fue 5,28 con un intervalo de confianza de 0,010 a 2918. Aunque la Hessiana fue definida y el algoritmo convergió, `glmmTMB::diagnose()` advirtió coeficientes y estadísticos $z$ anormalmente grandes, por lo que esa estimación no debe interpretarse como un efecto sustantivo. Esto indica que las asociaciones climáticas estimadas en el modelo principal deben interpretarse condicionadas a la memoria epidemiológica y no como efectos aislados.

Quinto, los modelos p90 con rezagos presentaron casi-separación. El modelo p90 con clima original alcanzó un coeficiente máximo de 204 y el modelo con rezagos de 933; este último mostró

además una Hessiana no definida en la validación temporal. Por ello, sus reducciones de AIC y sus OR por rezago no se consideran evidencia estable de un mejor mecanismo climático. La comparación más informativa es la del clima original en p90, que mejoró la AUC de prueba de 0,936 a 0,944, una diferencia modesta.

Finalmente, el modelo no fue concebido como herramienta de pronóstico. La clasificación binaria del brote descarta la magnitud de la incidencia y la estructura AR(1) de alta persistencia hace que las proyecciones fuera de muestra sean especialmente sensibles a shocks no observados. La validación temporal 2014–2019/2020–2022 es retrospectiva y de un solo corte; futuras extensiones deberían incorporar validación temporal externa con múltiples orígenes, datos entomológicos y de movilidad, y un análisis espacial explícito para evaluar la dependencia entre departamentos.

## 9. Reproducibilidad y Disponibilidad de Materiales

Con el fin de facilitar la replicación y la extensión de este análisis, todos los materiales asociados al estudio se encuentran disponibles públicamente bajo licencia MIT en el repositorio de GitHub del proyecto. El repositorio incluye:

- El script de limpieza y construcción del panel (`01-cleaning.R`), que documenta la descarga de los registros epidemiológicos de OpenDengue (Clarke et al., 2025), la extracción de las series climáticas de Open-Meteo (2024).
- El script de modelado (`03-GLMM.R`), que especifica los *Generalized Linear Mixed Models* en `glmmTMB` (Brooks et al., 2017), la construcción de los umbrales departamentales (percentil 75), el cálculo de las variables de inercia epidémica y precipitación acumulada, y los diagnósticos de residuales con `DHARMa` (Hartig, 2022).
- El script de sensibilidad (`04-sensitivity.R`), que reproduce el umbral alternativo p90, los rezagos climáticos de 2 a 4 semanas, la comparación inercia–clima, la validación temporal 2014–2019/2020–2022 y los diagnósticos de convergencia y separación.
- El archivo `main.tex` y la base bibliográfica `references.bib` que generan este documento.
- La base procesada final (`dengue_dataframe.csv` y `Etapas_dengue.csv`), lista para reproducir las estimaciones reportadas en la Tabla 2.

## 10. Conclusiones

Este estudio aporta evidencia de que la probabilidad de que un departamento en Nicaragua detone un brote de dengue responde a una interacción entre la memoria epidemiológica local y choques climáticos exógenos. Al aislar la elevada persistencia del contagio semanal mediante una estructura autorregresiva ($\rho = 0.96$), se observó que la precipitación acumulada en tres semanas y la temperatura media se asocian positivamente con el riesgo de brote. No obstante, el análisis de sensibilidad mostró que el bloque climático original aporta información medible sobre la inercia (mejor AIC y una mejora modesta de la AUC temporal en el umbral p90), mientras que los rezagos específicos de 2 a 4 semanas no mejoraron de forma estable y los modelos p90 con rezagos presentaron casi-separación. Por tanto, los resultados respaldan un aporte climático condicionado a la inercia epidémica, no un efecto aislado ni una capacidad predictiva robusta. En contraste, la anomalía de Niño 3.4 no mostró una asociación independiente robusta una vez controlados la estacionalidad mensual y la tendencia anual.

En términos sustantivos, estos hallazgos aportan evidencia cuantitativa sobre los factores ambientales asociados a la transición hacia fases epidémicas a escala departamental. Dado que

la dinámica del dengue se encuentra fuertemente dominada por la inercia semanal de casos, los resultados sugieren que las intervenciones de vigilancia y control podrían beneficiarse de incorporar información sobre anomalías hídricas acumuladas, no como un mecanismo de pronóstico operativo, sino como un criterio adicional para caracterizar el riesgo relativo entre departamentos y semanas.

## Declaración de Conflicto de Interés

El autor declara no tener conflicto de interés alguno en relación con este trabajo.

## Referencias


Anyamba, A., Chretien, J.-P., Britch, S. C., Soebiyanto, R. P., Small, J. L., Jepsen, R., Forshey, B. M., Sanchez, J. L., Smith, R. D., Harris, R., Tucker, C. J., Karesh, W. B., & Linthicum, K. J. (2019). Global disease outbreaks associated with the 2015–2016 El Niño event. *Scientific Reports*, *9*, 1930. https://doi.org/10.1038/s41598-018-38034-z

Benchimol, E. I., Smeeth, L., Guttmann, A., Harron, K., Moher, D., Petersen, I., Sørensen, H. T., von Elm, E., & Langan, S. M. (2015). The REporting of studies Conducted using Observational Routinely-collected health Data (RECORD) statement. *PLOS Medicine*, *12*(10), e1001885. https://doi.org/10.1371/journal.pmed.1001885

Bhatt, S., Gething, P. W., Brady, O. J., Messina, J. P., Farlow, A. W., Moyes, C. L., Drake, J. M., Brownstein, J. S., Hoen, A. G., Sankoh, O., Myers, M. F., George, D. B., Jaenisch, T., Wint, G. R. W., Simmons, C. P., Scott, T. W., Farrar, J. J., & Hay, S. I. (2013). The global distribution and burden of dengue. *Nature*, *496*(7446), 504-507. https://doi.org/10.1038/nature12060

Bowman, L. R., Runge-Ranzinger, S., & McCall, P. J. (2014). Assessing the relationship between vector indices and dengue transmission: a systematic review of the evidence. *PLOS Neglected Tropical Diseases*, *8*(5), e2848. https://doi.org/10.1371/journal.pntd.0002848

Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time Series Analysis: Forecasting and Control* (5.ª ed.). Wiley.

Brady, O. J., Gething, P. W., Bhatt, S., Messina, J. P., Brownstein, J. S., Hoen, A. G., Moyes, C. L., Farlow, A. W., Scott, T. W., & Hay, S. I. (2012). Refining the global spatial limits of dengue virus transmission by evidence-based consensus. *PLOS Neglected Tropical Diseases*, *6*(8), e1760. https://doi.org/10.1371/journal.pntd.0001760

Breslow, N. E., & Clayton, D. G. (1993). Approximate Inference in Generalized Linear Mixed Models. *Journal of the American Statistical Association*, *88*(421), 9-25. https://doi.org/10.1080/01621459.1993.10594284

Brooks, M. E., Kristensen, K., van Benthem, K. J., Magnusson, A., Berg, C. W., Nielsen, A., Skaug, H. J., Mächler, M., & Bolker, B. M. (2017). glmmTMB balances speed and flexibility among packages for zero-inflated generalized linear mixed modeling. *The R Journal*, *9*(2), 378-400. https://doi.org/10.32614/RJ-2017-066

Clarke, J., Lim, A., Gupte, P. R., Pigott, D. M., van Panhuis, W. G., & Brady, O. J. (2025). OpenDengue: data from the OpenDengue database [Version 1.3]. https://doi.org/10.6084/m9.figshare.24259573

Diggle, P. J., Heagerty, P., Liang, K.-Y., & Zeger, S. L. (2002). *Analysis of Longitudinal Data* (2.ª ed.). Oxford University Press.

Fitzmaurice, G. M., Laird, N. M., & Ware, J. H. (2011). *Applied Longitudinal Analysis* (2.ª ed.). Wiley.

Gordon, A., Kuan, G., Mercado, J. C., Gresh, L., Avilés, W., Balmaseda, A., & Harris, E. (2013). The Nicaraguan Pediatric Dengue Cohort Study: Incidence of inapparent and symptomatic dengue virus infections, 2004–2010. *PLOS Neglected Tropical Diseases*, *7*(9), e2462. https://doi.org/10.1371/journal.pntd.0002462

Hartig, F. (2022). *DHARMa: Residual Diagnostics for Hierarchical (Multi-Level / Mixed) Regression Models* [R package version 0.4.6]. https://CRAN.R-project.org/package=DHARMa

McCullagh, P., & Nelder, J. A. (1989). *Generalized Linear Models* (2.ª ed.). Chapman & Hall.

Mordecai, E. A., Caldwell, J. M., Grossman, M. K., Lippi, C. A., Johnson, L. R., Neira, M., Rohr, J. R., Ryan, S. J., Savage, V., Shocket, M. S., Sippy, R., Stewart Ibarra, A. M., Thomas,

M. B., & Villena, O. (2019). Thermal biology of mosquito-borne disease. *Ecology Letters*, *22*(10), 1690-1708. https://doi.org/10.1111/ele.13335

Mordecai, E. A., Cohen, J. M., Evans, M. V., Gudapati, P., Johnson, L. R., Lippi, C. A., Miazgowicz, K., Murdock, C. C., Rohr, J. R., Ryan, S. J., Savage, V., Shocket, M. S., Stewart Ibarra, A. M., Thomas, M. B., & Weikel, D. P. (2017). Detecting the impact of temperature on transmission of Zika, dengue, and chikungunya using mechanistic models. *PLOS Neglected Tropical Diseases*, *11*(4), e0005568. https://doi.org/10.1371/journal.pntd.0005568

Morin, C. W., Comrie, A. C., & Ernst, K. (2013). Climate and dengue transmission: evidence and implications. *Environmental Health Perspectives*, *121*(11–12), 1264-1272. https://doi.org/10.1289/ehp.1306556

NOAA Climate Prediction Center. (2026). *Weekly OISST v2.1 Niño region sea surface temperature indices* [Accessed: 2026-11-09]. https://www.cpc.ncep.noaa.gov/data/indices/wksst9120.for

Open-Meteo. (2024). Historical Weather API: Past weather data archive [Accessed: 2026-10-05]. https://open-meteo.com/en/docs/historical-weather-api

Organización Panamericana de la Salud. (2002). *Módulos de principios de epidemiología para el control de enfermedades (MOPECE): Módulo 5: Investigación epidemiológica de campo: aplicación al estudio de brotes* (2.ª). https://iris.paho.org/handle/10665.2/40137

Pinheiro, J. C., & Bates, D. M. (2000). *Mixed-Effects Models in S and S-PLUS*. Springer.

Shmueli, G. (2010). To Explain or to Predict? *Statistical Science*, *25*(3), 289-310. https://doi.org/10.1214/10-STS330

Standish, K., Kuan, G., Avilés, W., Balmaseda, A., & Harris, E. (2010). High dengue case capture rate in four years of a cohort study in Nicaragua compared to national surveillance data. *PLOS Neglected Tropical Diseases*, *4*(3), e633. https://doi.org/10.1371/journal.pntd.0000633

Suazo-Laguna, H., Mojica-DÍaz, J., Lopez, M. M., Balmaseda, A., Harris, E., Coloma, J., & Juarez, J. G. (2026). Abundance of the vector *Aedes aegypti* in urban and rural areas in Managua, Nicaragua. *PLOS Neglected Tropical Diseases*, *20*(4), e0014256. https://doi.org/10.1371/journal.pntd.0014256

von Elm, E., Altman, D. G., Egger, M., Pocock, S. J., Gøtzsche, P. C., & Vandenbroucke, J. P. (2007). The Strengthening the Reporting of Observational Studies in Epidemiology (STROBE) statement: guidelines for reporting observational studies. *The Lancet*, *370*(9596), 1453-1457. https://doi.org/10.1016/S0140-6736(07)61602-X

Zuur, A. F., Ieno, E. N., & Elphick, C. S. (2010). A protocol for data exploration to avoid common statistical problems. *Methods in Ecology and Evolution*, *1*(1), 3-14. https://doi.org/10.1111/j.2041-210X.2009.00001.x