Determinantes Ambientales y Persistencia Temporal en los Brotes de Dengue en Nicaragua (2014–2022)

Emerson Lopez
emerson.zeledon.ni@gmail.com

9 de noviembre de 2026

Resumen

Este documento presenta la formulación metodológica, especificación matemática, resultados empíricos y análisis de residuales para el modelamiento de la probabilidad de brotes de dengue en los 18 departamentos de Nicaragua durante el período 2014-2022. Utilizando un Modelo Lineal Mixto Generalizado (GLMM) con distribución binomial y función de enlace logit, se incorporaron efectos aleatorios espaciales y una estructura autorregresiva temporal de primer orden (AR(1)) para aislar la inercia epidémica y evaluar el impacto de variables climáticas (precipitación acumulada y temperatura) y el fenómeno de El Niño. Los resultados muestran una persistencia epidémica semanal extrema ($\rho = 0{,}96$), un efecto multiplicativo dominante de la inercia de casos previos (OR $\approx 16{,}77$ ante duplicación de casos), una asociación positiva de la precipitación acumulada y de la temperatura media, mientras que la anomalía de Niño 3.4 no alcanzó significancia estadística.

1. Introducción y Definición del Evento

El dengue constituye una de las arbovirosis de mayor propagación y carga para la salud pública global, afectando primordialmente a regiones tropicales y subtropicales de América Latina y el sudeste asiático (Bhatt et al., 2013). Transmitido predominantemente por hembras infectadas del mosquito *Aedes aegypti*, la dispersión del virus del dengue (DENV, serotipos 1–4) está ligada tanto a factores ecológicos y climáticos como a procesos demográficos y de gestión ambiental urbana (Brady et al., 2012; Morin et al., 2013).

En Nicaragua, el dengue se comporta como una enfermedad endémica e hiperendémica con manifestaciones epidémicas recurrentes de alta intensidad (Gordon et al., 2013). Si bien la transmisión basal persiste durante todo el año, la probabilidad de que un territorio transite hacia una fase epidémica descontrolada depende de la conjunción entre la inercia biológica local (la abundancia de individuos infecciosos y mosquitos activos) y choques hidroclimáticos que expanden los reservorios y aceleran la replicación viral (Anyamba et al., 2019; Suazo-Laguna et al., 2026).

Desde la perspectiva de la vigilancia epidemiológica, modelar el dengue en zonas hiperendémicas presenta desafíos estadísticos notables. Tradicionalmente, la transición hacia una fase de alerta sanitaria no se evalúa únicamente mediante el conteo absoluto de contagios, sino mediante la identificación de umbrales que superan el comportamiento esperado histórico del territorio (Organización Panamericana de la Salud, 2002). En este estudio, se define el evento binario de *brote* ($\text{brote}_{it} = 1$) para el departamento i en la semana epidemiológica t cuando el recuento semanal de casos confirmados supera el percentil 75 empírico calculado sobre toda su serie histórica 2014–2022, sin estratificar por semana epidemiológica. Esta formulación permite estandarizar la alerta independientemente del tamaño poblacional basal de cada región y capturar la probabilidad condicional de que un territorio detone una fase de alarma sanitaria.

El objetivo principal de esta investigación es evaluar el impacto relativo de las precipitaciones acumuladas a corto plazo, la temperatura ambiente y el macroclima modulado por el fenómeno de El Niño sobre la probabilidad de detonar brotes departamentales en Nicaragua durante 2014–2022, aislando la inercia serial.

2. Revisión de Literatura

2.1. Eco-epidemiología del Dengue y Forzantes Climáticos

La relación entre las fluctuaciones meteorológicas y la dinámica de transmisión de las arbovirosis está respaldada por una amplia base biofísica (Mordecai et al., 2019; Morin et al., 2013). La temperatura ambiente gobierna parámetros vitales de *Aedes aegypti*, tales como la tasa de picadura, la longevidad del mosquito y el período de incubación extrínseca (EIP) del virus, el cual se contrae significativamente en intervalos térmicos cálidos entre 24 °C y 30 °C (Mordecai et al., 2017). No obstante, en ecosistemas de tierras bajas tropicales donde las temperaturas permanecen de forma continua dentro de la ventana permisiva para el virus, la variabilidad de la temperatura semanal suele tener un poder explicativo marginal en comparación con los regímenes de precipitación.

Por su parte, la precipitación pluvial actúa como el forzante hídrico primario al propiciar criaderos para los estadios inmaduros (larvas y pupas) (Bowman et al., 2014). Como han demostrado estudios entomológicos recientes en Nicaragua, la acumulación de recipientes y reservorios de almacenamiento hídrico modula directamente la productividad pupal y la densidad de hembras adultas tanto en sectores urbanos como rurales (Suazo-Laguna et al., 2026). Dado que el ciclo biológico completo (oviposición, desarrollo acuático, emergencia del adulto, ingestión del virus y maduración extrínseca) abarca típicamente entre dos y cuatro semanas, el efecto de

las lluvias sobre los contagios humanos se manifiesta con rezagos acumulados y no como una respuesta contemporánea inmediata (Anyamba et al., 2019; Morin et al., 2013).

A escala sinóptica, las oscilaciones macroclimáticas asociadas al ciclo de El Niño–Oscilación del Sur (ENSO) alteran los patrones pluviométricos y térmicos interanuales en Centroamérica (Anyamba et al., 2019). Las anomalías positivas persistentes de la temperatura superficial del mar en la región Niño 3.4, registradas semanalmente (NOAA Climate Prediction Center, 2026), coinciden frecuentemente con sequías estacionales seguidas de eventos pluviales concentrados o aumentos térmicos anómalos, los cuales favorecen el almacenamiento domiciliario de agua y amplifican el riesgo de epidemias masivas, tal como se registró en la región en 2015–2016 y 2019.

2.2. Evidencia Epidemiológica Previa en Nicaragua

La epidemiología del dengue en Nicaragua ha sido objeto de investigaciones longitudinales exhaustivas, primordialmente a través del Estudio de la Cohorte Pediátrica de Dengue (PDCS) en Managua (Gordon et al., 2013; Standish et al., 2010). Dichos estudios han documentado la circulación alternante de serotipos virales, la dinámica de transmisión sintomática frente a infecciones inaparentes y la alta eficiencia en la captación de casos dentro del sistema de vigilancia (Standish et al., 2010). Asimismo, estudios locales sobre la distribución de *Aedes aegypti* en distritos de Managua demuestran que las poblaciones del vector persisten con elevadas densidades a lo largo de las estaciones seca y lluviosa, amplificadas por prácticas de almacenamiento de agua (Suazo-Laguna et al., 2026).

A pesar de este sólido cuerpo de literatura biomédica y entomológica, la mayor parte de las investigaciones empíricas nicaragüenses se han concentrado a escala comunitaria o distrital en la capital (Managua). Existe una brecha en la evaluación inferencial multianual que abarque la totalidad de los 18 departamentos y regiones autónomas bajo un diseño de datos de panel, controlando explícitamente tanto la heterogeneidad espacial como la extrema persistencia autorregresiva de la vigilancia semanal.

2.3. Consideraciones Metodológicas y Dependencia Serial

El modelado estadístico de series temporales de vigilancia epidemiológica en paneles geográficos exige abordar dos retos econométricos esenciales: la heterogeneidad estructural no observada entre regiones y la fuerte autocorrelación temporal (Zuur et al., 2010). Ignorar la dependencia serial conduce a estimaciones artificialmente precisas de los errores estándar y genera significancia espuria en las covariables climáticas exógenas.

La integración de Modelos Lineales Mixtos Generalizados (GLMM) con enlace logit (Breslow & Clayton, 1993; Pinheiro & Bates, 2000) y procesos autorregresivos de primer orden (AR(1)) en las componentes estocásticas permite disociar la inercia interna del brote respecto a los choques climáticos exógenos (Diggle et al., 2002). Al formular el modelo con propósitos confirmatorios e inferenciales guiados por la eco-epidemiología y no por minería algorítmica de especificaciones (*data dredging*) (Shmueli, 2010), se garantiza una interpretación robusta de las razones de momios asociadas al riesgo de brote.

3. Metodología

La especificación del modelo se definió *a priori* con base en la literatura eco-epidemiológica sobre determinantes del dengue (Anyamba et al., 2019; Mordecai et al., 2019) y en la estructura jerárquica del panel longitudinal. La inclusión del intercepto aleatorio departamental responde a la necesidad de controlar la heterogeneidad estructural no observada entre regiones, mientras que la estructura AR(1) se incorporó para mitigar la dependencia serial inherente a las series semanales de vigilancia epidemiológica (Zuur et al., 2010). Asimismo, las covariables climáticas

se seleccionaron por su asociación biofísica documentada con el ciclo del vector. No se realizó una búsqueda exhaustiva de especificaciones alternativas (como selección paso a paso o *data dredging*), dado que el objetivo primordial del estudio es inferencial y confirmatorio, y no predictivo (Shmueli, 2010). El reporte de este estudio sigue las directrices STROBE (von Elm et al., 2007) y RECORD (Benchimol et al., 2015) para estudios observacionales y de datos rutinarios.

3.1. Datos

Los registros epidemiológicos provienen de la plataforma global OpenDengue (Clarke et al., 2025), que en esta extracción reporta únicamente casos confirmados a escala semanal y por departamento, sin distinguir entre casos probables, clínicos o graves. Se retuvieron las observaciones con resolución temporal semanal (`T_res = "Week"`) y granularidad administrativa de primer nivel (`adm_1_name`), lo que arroja un panel de 18 departamentos/regiones autónomas observados semanalmente. La serie cruda abarca desde el 5 de enero de 2014 hasta el 6 de noviembre de 2022. Tras construir los rezagos y la precipitación acumulada de tres semanas, la muestra de modelado comprende 8.280 registros semanales (460 semanas por departamento) desde el 19 de enero de 2014 hasta el 6 de noviembre de 2022. Las coordenadas geográficas de referencia para cada unidad territorial se presentan en la Tabla 1.

Tabla 1: Departamentos de Nicaragua y coordenadas geográficas de referencia

Departamento / Región	**Latitud (°N)**	**Longitud (°O)**
BILWI	14.0351	-83.3888
BOACO	12.4722	-85.6586
CARAZO	11.8540	-86.2000
CHINANDEGA	12.6294	-87.1311
CHONTALES	12.1063	-85.3645
ESTELI	13.0918	-86.3538
GRANADA	11.9299	-85.9560
JINOTEGA	13.0988	-86.0022
LEON	12.4379	-86.8780
MADRIZ	13.4667	-86.5833
MANAGUA	12.1364	-86.2514
MASAYA	11.9744	-86.0942
MATAGALPA	12.9256	-85.9175
NUEVA SEGOVIA	13.6333	-86.4833
REGION AUTONOMA DEL ATLANTICO SUR	12.0137	-83.7635
RIO SAN JUAN	11.1097	-84.7797
RIVAS	11.4372	-85.8263
ZELAYA CENTRAL	12.0000	-84.2833

A partir de las coordenadas departamentales (Tabla 1), se extrajeron las series climáticas de temperatura media y precipitación acumulada diaria con la API histórica de Open-Meteo (2024)[1], se agregaron a escala semanal tomando la media para temperatura y la suma para precipitación. El índice temporal semanal (`tiempo_factor`) se definió como la fecha de inicio de cada semana epidemiológica (domingo), construida con `lubridate::floor_date(..., unit = "week", week_start = 7)`. La precipitación acumulada de tres semanas (`Rain_acc3`) se calculó como una suma móvil alineada a la derecha (`RcppRoll::roll_sum`).

La variable explicada corresponde al evento binario de brote$_{it}$, definida como 1 en aquellas semanas epidemiológicas donde la incidencia superó el percentil 75 empírico calculado dentro de cada departamento sobre toda su serie 2014–2022 y no dentro de cada semana epidemiológica,

[1]Para la Región Autónoma del Atlántico Sur se tomaron las coordenadas de Bluefields; para Río San Juan, las de San Carlos; y para Zelaya Central, las del municipio de El Rama.

siguiendo el criterio de canal endémico establecido por la Organización Panamericana de la Salud (2002). El umbral se redondeó hacia abajo al entero más cercano con `floor()` para respetar la naturaleza discreta de `dengue_total`. La anomalía macroclimática de El Niño se incorporó como la media móvil de 12 semanas de la anomalía de la temperatura superficial del mar en la región Niño 3.4 (`nino34_12s`), construida a partir de NOAA Climate Prediction Center (2026). El resto de covariables son la precipitación acumulada de tres semanas (`Rain_acc3`), la temperatura media semanal (`Temperature`), la inercia epidémica capturada mediante el logaritmo natural de los casos de la semana anterior más uno, $\ln(\text{casos}_{t-1}+1)$, denotado `ln_casos_semana_anterior`, y controles temporales de estacionalidad mensual (`mes`) y tendencia anual (`year`).

El panel crudo presentó 36 departamento-semanas sin registro (0,4 % del panel completo de 8.316). Para mantener una serie semanal regular, la grilla se completó con la función `fill_gaps()` de `tsibble` y `dengue_total` se imputó mediante interpolación lineal dentro de cada departamento con la función `na_interpolation(..., option = "linear")` de `imputeTS`; las brechas residuales de temperatura y lluvia semanal también se interpolaron linealmente dentro del departamento. La imputación supone transiciones suaves y datos faltantes no informativos, y no propaga la incertidumbre de imputación a los errores estándar ni a los intervalos de confianza.

Todos los análisis se realizaron en R con paquetes instalados desde un snapshot de Posit Package Manager con fecha 2026-09-16. Los paquetes clave empleados fueron `glmmTMB`, `DHARMa`, `performance`, `ggeffects`, `broom.mixed`, `tsibble`, `imputeTS` y `RcppRoll`.

Para modelar la probabilidad de brote controlando simultáneamente la heterogeneidad espacial y la dependencia serial, se formuló un Modelo Lineal Mixto Generalizado (GLMM) con función de enlace logit (Breslow & Clayton, 1993; Pinheiro & Bates, 2000) implementado mediante la librería `glmmTMB` (Brooks et al., 2017) en R:

```
modelo_1 <- glmmTMB(
brote ~
nino34_12s +
Rain_acc3 +
Temperature +
ln_casos_semana_anterior +
mes +                    #estacionalidad mensual
year +                   #tendencia anual
(1 | DEPARTAMENTO) +  #intercepto aleatorio espacial
ar1(tiempo_factor + 0 | DEPARTAMENTO), #inercia temporal AR
    (1)
family = binomial(link = "logit"),
data = dengue_etapa1
)
```

4. Especificación Matemática

El modelo combina una regresión logística para el evento binario de brote con efectos aleatorios espaciales y una matriz de correlación temporal.

4.1. Componente Aleatorio y Función de Enlace

Dado que la variable de respuesta brote es binaria (0 = No hay brote, 1 = Sí hay brote), el modelo asume que el evento Y_{it} (para el departamento i en la semana t) sigue una distribución

de la familia Binomial[2] (McCullagh & Nelder, 1989):

$$Y_{it} \sim \text{Binomial}(1, p_{it}) \tag{1}$$

Para proyectar la probabilidad esperada de brote (p_{it}) en la escala real sin arrojar estimaciones fuera del intervalo $[0, 1]$, se utiliza la función de enlace Logit:

$$\text{logit}(p_{it}) = \ln\left(\frac{p_{it}}{1 - p_{it}}\right) = \eta_{it} \tag{2}$$

4.2. Predictor Lineal (η_{it})

La ecuación completa del modelo, que proyecta el riesgo combinando el clima y la inercia epidemiológica, se define como:

$$\begin{aligned}\text{logit}(p_{it}) = \beta_0 + \beta_1 \text{nino34_12s}_{it} + \beta_2 \text{Rain_acc3}_{it} + \beta_3 \text{Temperature}_{it} \\ + \beta_4 \ln\text{_casos_semana_anterior}_{it} + \sum_{m=2}^{12} \gamma_m \text{mes}_{m,it} + \sum_{y=2015}^{2022} \delta_y \text{year}_{y,it} + u_i + \omega_{it}\end{aligned} \tag{3}$$

4.3. Parámetros y Estructura Jerárquica

El modelo desglosa sus componentes estocásticos y sistemáticos de la siguiente forma:

- **Efectos Fijos (β):**
  - β_0: Intercepto global del modelo. Es el nivel basal de riesgo de brote (en escala log-odds) que sirve como punto de partida común a todos los departamentos, antes de incorporar el efecto del clima, la inercia epidémica y la desviación propia de cada departamento u_i. En términos prácticos, corresponde al riesgo log-odds esperado cuando todas las covariables valen cero y $u_i = 0$.
  - $\beta_1, \beta_2, \beta_3$: Coeficientes[3] lineales cuyos valores exponenciados (OR $= e^{\beta}$) representan la razón de momios (*Odds Ratio*) asociada a la anomalía de Niño 3.4 (promedio móvil de 12 semanas), a cada milímetro adicional de precipitación acumulada de tres semanas y a cada grado Celsius de temperatura media.
  - β_4: Coeficiente paramétrico de la inercia epidémica rezagada en escala logarítmica, donde el impacto multiplicativo sobre los *odds* ante un incremento por factor k en los casos previos se evalúa mediante k^{β_4} (por ejemplo, 2^{β_4} para una duplicación de casos).
  - γ_m, δ_y: Coeficientes de los controles fijos de estacionalidad mensual y tendencia anual, incluidos para absorber la variación temporal de largo plazo y evitar que el clima reciba una parte de la persistencia epidémica.

[2] Dado que cada fila del panel evalúa la presencia o ausencia del evento como un desenlace binario (1 = brote, 0 = no brote), el modelo estima la probabilidad semanal condicional del evento (p_{it}), cuya varianza depende de dicha probabilidad según la relación $p_{it}(1 - p_{it})$.

[3] Los coeficientes β (efectos fijos) se estiman a partir de los datos maximizando la verosimilitud (en términos intuitivos, el algoritmo busca los valores de β que mejor explican los brotes observados en los 8,280 registros del panel) del modelo. En concreto, `glmmTMB` (Brooks et al., 2017) aproxima la integral de la verosimilitud marginal mediante la aproximación de Laplace y obtiene los valores de β que hacen más probables las observaciones registradas, dados los efectos aleatorios. Cada β viene acompañado de un error estándar y un valor z, con los que se construyen los intervalos de confianza y las pruebas de significancia reportadas en la Tabla 2.

- **Efecto Aleatorio Espacial (u_i):**

$$u_i \sim \mathcal{N}(0, \sigma_u^2), \qquad i = 1, \ldots, 18. \tag{4}$$

Captura la heterogeneidad espacial no observada entre los 18 departamentos, permitiendo que cada región posea su propio nivel basal de riesgo endémico.

Este término corresponde a un intercepto aleatorio por departamento o región autónoma (Fitzmaurice et al., 2011) (`(1 | DEPARTAMENTO)`). No se estima una varianza independiente para cada departamento, sino una única varianza común σ_u^2 que describe cuán dispersos están los niveles basales de riesgo log-odds de los 18 departamentos alrededor del intercepto global β_0. Así, el intercepto efectivo del departamento i es $\beta_0 + u_i$. Este componente modela diferencias departamentales no observadas.

- **Efecto Aleatorio Temporal AR(1) (ω_{it}):** Para controlar la dependencia temporal serial dentro de cada unidad geográfica (`ar1(tiempo_factor + 0 | DEPARTAMENTO)`), se incorpora un efecto aleatorio ω_{it} que varía semana a semana dentro de cada departamento y que captura toda la persistencia temporal no explicada por las covariables. Para cada departamento i, el vector de estos efectos a lo largo de las T semanas, $\boldsymbol{\omega}_i = (\omega_{i1}, \ldots, \omega_{iT})^\top$, se modela como un proceso gaussiano con media cero y estructura de covarianza autorregresiva de primer orden (Diggle et al., 2002):

$$\mathrm{Cov}(\omega_{it}, \omega_{is}) = \sigma_\omega^2 \rho^{|t-s|}. \tag{5}$$

Los dos parámetros que gobiernan esta estructura tienen una interpretación directa:

  - σ_ω^2: varianza del efecto temporal. Mide la magnitud típica de las fluctuaciones aleatorias que experimenta la probabilidad de brote semana a semana en un mismo departamento, una vez descontado el efecto de las covariables y del intercepto departamental. Un valor grande indica que existen factores temporales no observados que mueven el riesgo de manera sustancial.
  - ρ: coeficiente de autocorrelación de primer orden. Mide cuán parecido es el efecto de una semana con el de la semana inmediatamente anterior. Sus valores están acotados entre -1 y 1; un ρ cercano a 1 implica que la serie temporal del riesgo es muy persistente (lo que ocurre esta semana se parece mucho a lo que ocurrió la semana pasada), mientras que un ρ cercano a 0 implica que la memoria se disipa rápido.

La expresión $\rho^{|t-s|}$ cuantifica la correlación entre dos semanas cualesquiera separadas por $|t - s|$ pasos (Box et al., 2015). Por ejemplo, si $\rho = 0.96$, la correlación entre semanas contiguas ($|t-s| = 1$) es 0.96; entre semanas separadas por dos períodos es $0.96^2 \approx 0.92$; y decae de forma exponencial conforme aumenta la distancia temporal. La forma gaussiana del proceso implica que, para cada departamento, ω_{it} sigue una distribución normal con varianza constante σ_ω^2 y correlación decreciente con el tiempo.

En términos sustantivos, este componente permite distinguir el efecto genuino de las covariables climáticas del simple arrastre epidémico que se hereda de una semana a otra. Sin él, el modelo atribuiría al clima una parte de la persistencia que en realidad es inercia interna del brote, inflando artificialmente la significancia de variables como la precipitación. La evidencia empírica de un $\rho = 0.96$ (Tabla 2) confirma que la probabilidad de brote en un departamento está fuertemente condicionada por su estado en la semana anterior.

Tabla 2: Resultados del Modelo GLMM Binomial con Inercia AR(1)

Efectos Fijos	**Estimación (β)**	**Error Est.**	z	**Valor p**
(Intercepto)	-24.456	2.110	-11.59	< 0.001
Anomalía Niño 3.4 (12 sem)	0.132	0.117	1.14	0.256
Precipitación acum. (`Rain_acc3`)	0.00239	< 0.001	3.32	< 0.001
Temperatura (`Temperature`)	0.240	0.078	3.08	0.002
Casos previos (`ln_casos_semana_anterior`)	4.068	0.160	25.47	< 0.001
Efectos Aleatorios	**Varianza**	**Desv. Est.**	**Parámetro**	
Intercepto por Departamento (σ_u^2)	5.429	2.330	-	
Efecto temporal AR(1) (σ_ω^2)	0.912	0.955	$\rho = 0.96$	
Bondad de Ajuste: AIC = 3602.8	BIC = 3792.3	Obs = 8280	Grupos = 18	

5. Resultados

5.1. Estimaciones del Modelo y Odds Ratios

Además de estos efectos, el modelo incluye controles fijos de mes y año para absorber estacionalidad y tendencia; sus coeficientes se omiten de la tabla por espacio.

Los resultados de la estimación del modelo de brote se resumen en la Tabla 3.

Tabla 3: Razones de momios del modelo

Variable	Cambio en Odds (%)
(Intercepto)	-
El Niño (anomalía 12 sem)	+14.1 %
Precipitación acum. 3 sem	+0.24 % por mm
Temperatura media	+27.1 %
Log-casos semana anterior	$2^{4.068} \approx 16.77\times$

La precipitación acumulada y la temperatura media resultaron estadísticamente significativas al 5 %, mientras que la anomalía de Niño 3.4 no alcanzó significancia (p=0.256). El efecto térmico positivo es consistente con la eco-epidemiología de zonas tropicales bajas: dentro de la ventana térmica permisiva para el vector (aproximadamente 24–30 °C), incrementos en la temperatura media semanal se asocian con una mayor probabilidad de brote (Mordecai et al., 2017).

En cuanto a la anomalía de Niño 3.4, el odds ratio estimado es 1.141 (IC 95 %: 0.908 a 1.434; p=0.256), manteniendo las demás variables constantes. Al excluir la tendencia anual, el OR asciende a 1.20 (IC 95 %: 0.987 a 1.46; p=0.067), lo que sugiere que su señal es frágil y se solapa con la variación macroclimática de largo plazo.[4]

Para la variable de inercia epidémica (`ln_casos_semana_anterior`), el coeficiente $\beta = 4.068$ indica un riesgo multiplicativo masivo. Evaluando un factor de duplicación de casos respecto a la semana anterior mediante la fórmula $\text{OR} = (\text{factor})^{\beta}$:

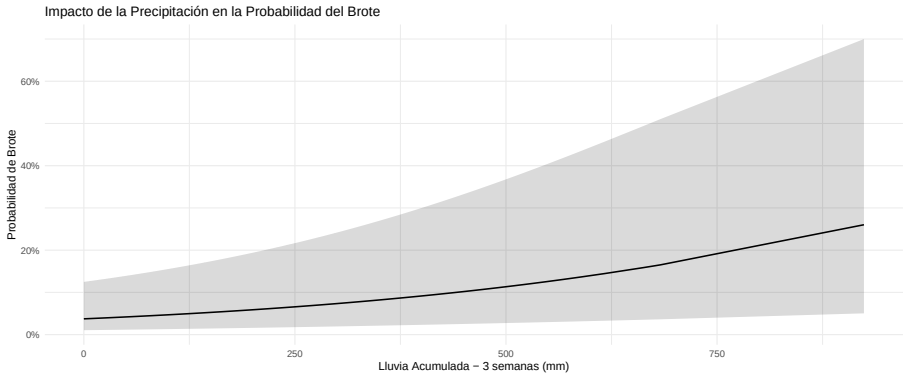
$$\text{OR} = 2^{4.068} \approx 16.77 \tag{6}$$

Es decir, duplicar los casos de la semana previa se asocia con un aumento de aproximadamente 16.77 veces en los odds de desencadenar un brote (IC 95 %: 13.50 a 20.83). La estructura temporal

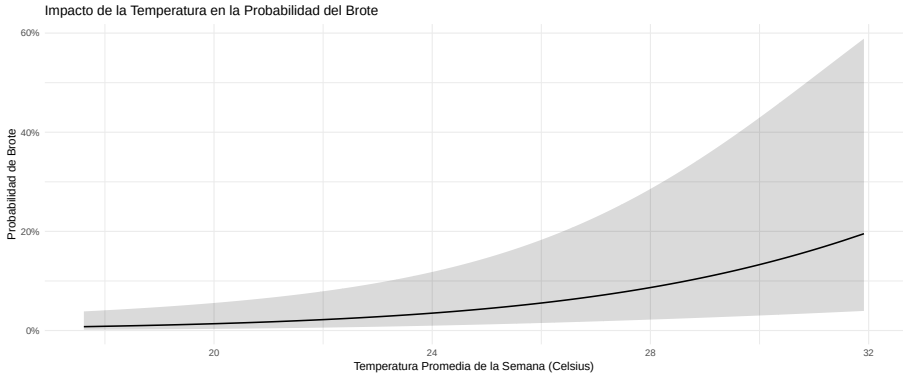
[4]Los intervalos de confianza al 95 % para las razones de momios se obtuvieron mediante el método de Wald, transformando los límites del intervalo de confianza del coeficiente β en escala log-odds: $\text{IC}_{95\,\%}(\text{OR}) = \exp\left(\hat{\beta} \pm 1.96 \cdot \text{EE}(\hat{\beta})\right)$. Para la anomalía de Niño 3.4, con $\hat{\beta} = 0.132$ y EE = 0.117, se obtiene $\exp(0.132 \pm 1.96 \cdot 0.117) = \exp(-0.097, 0.361) = (0.908, 1.435)$, lo que equivale a un cambio porcentual entre -9.2 % y $+43.5$ %. El mismo procedimiento se aplicó al resto de las covariables.

reveló un parámetro autorregresivo $\rho = 0.96$. Esto indica que la incidencia semanal hereda casi la totalidad del comportamiento inmediato anterior dentro del mismo departamento.

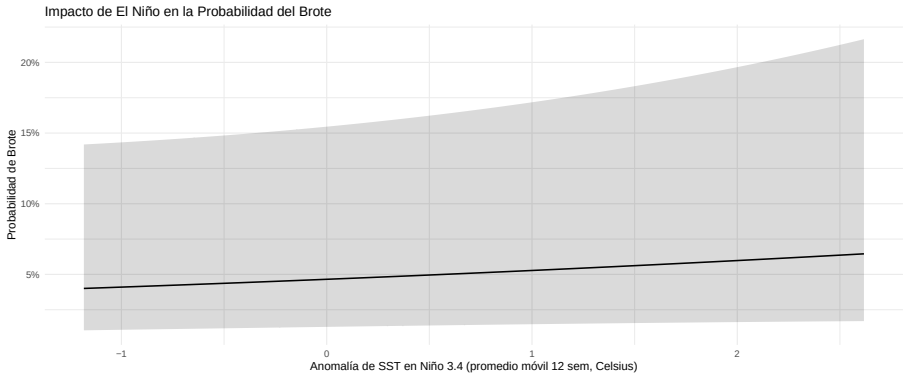
5.2. Análisis Gráfico de Efectos



(a) Precipitación acumulada



(b) Temperatura media



(c) Anomalía de Niño 3.4

Figura 1: Efectos marginales de la precipitación acumulada, la temperatura y la anomalía de Niño 3.4.

Como se observa en la Figura 1, la probabilidad de brote aumenta con la precipitación acumulada y con la temperatura media. En el panel superior, la relación con la precipitación es no lineal: el efecto es más pronunciado en el tramo inicial y la banda de confianza se amplía hacia valores extremos. En el panel central, el efecto de la temperatura es positivo y más lineal. En el panel inferior, la curva de Niño 3.4 es casi plana y la banda de confianza es amplia, lo que refleja la falta de una asociación independiente robusta.

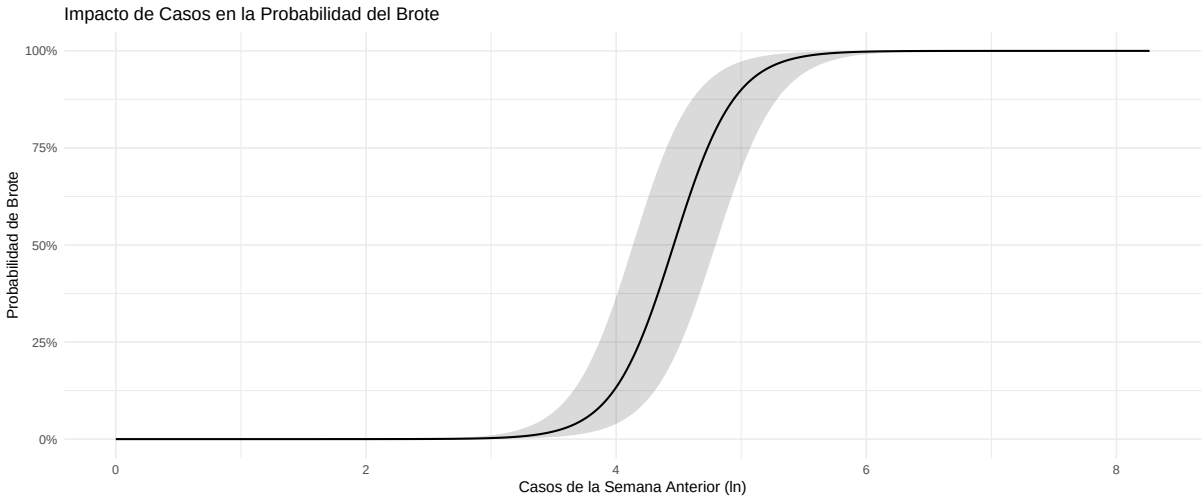


Figura 2: Efecto de Casos de la Semana Anterior

Por su parte, la Figura 2 muestra un marcado umbral de quiebre: con casos rezagados por debajo de 3.5 en escala logarítmica, la probabilidad de brote es cercana al 0 %. Entre los valores 4 y 5, la curva experimenta una pendiente casi vertical, disparando la probabilidad hasta saturarse al 100 % cuando se superan los 6 puntos logarítmicos.

6. Residuales y Diagnóstico del Modelo

Tabla 4: Diagnóstico de Multicolinealidad (VIF y Tolerancia)

Covariable	**VIF**	**IC 95 % VIF**	**VIF Aj.**	**Tolerancia**	**IC 95 % Tol.**
Niño 3.4 (12 sem)	1.65	[1.60, 1.70]	1.28	0.61	[0.59, 0.62]
Precipitación acum.	2.19	[2.12, 2.27]	1.48	0.46	[0.44, 0.47]
Temperatura	2.15	[2.09, 2.23]	1.47	0.46	[0.45, 0.48]
Casos previos	1.26	[1.23, 1.29]	1.12	0.80	[0.77, 0.82]
Mes	4.65	[4.47, 4.83]	2.16	0.22	[0.21, 0.22]
Año	2.17	[2.10, 2.24]	1.47	0.46	[0.45, 0.48]

La evaluación de colinealidad mediante los factores de inflación de varianza (VIF) arrojó valores de hasta 4.65 para las covariables. El VIF más alto corresponde a mes (4.65), seguido de año (2.17), ambos por debajo del umbral convencional de 5; los VIF ajustados se mantienen por debajo de 2.2, descartando problemas de multicolinealidad.

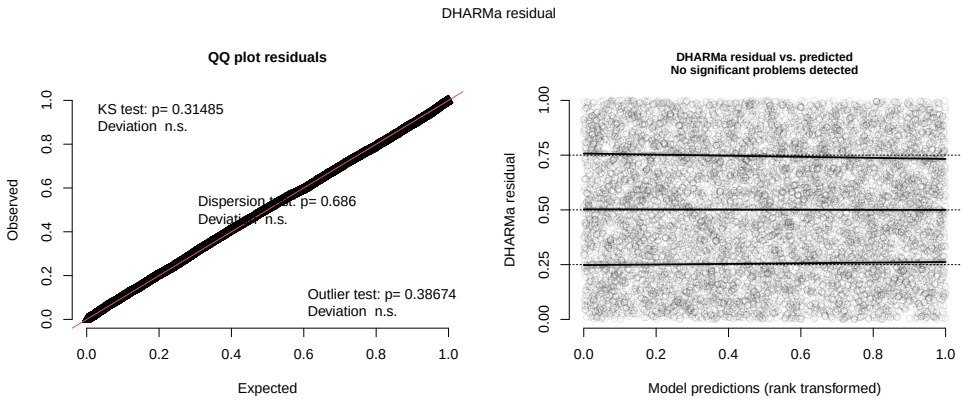


Figura 3: Diagnóstico de residuales mediante simulación DHARMa.

Para validar los supuestos distribucionales y la ausencia de sobredispersión, se aplicó la prueba de simulación de residuales vía `DHARMa` (Hartig, 2022) (Figura 3). Los residuales pasan las pruebas de no desviación significativa ($p = 0.31$), no sobredispersión ($p = 0.69$) y ausencia de valores atípicos ($p = 0.387$), manteniendo cuantiles alineados.

Adicionalmente, la evaluación de autocorrelación temporal sobre los residuales agrupados por fecha de inicio mediante la prueba de Durbin-Watson arrojó un estadístico DW = 1.8589 con un valor $p = 0.1294$, por lo que no se detectó autocorrelación temporal remanente. Cabe precisar que la prueba de Durbin-Watson evalúa dependencia temporal, no autocorrelación espacial.

7. Discusión

El modelo propuesto demostró un ajuste riguroso al superar las pruebas de simulación de residuales, sobredispersión y autocorrelación temporal. No obstante, para futuras líneas de investigación se sugiere profundizar en la calibración del umbral epidemiológico para Nicaragua, evaluando alternativas locales al percentil 75 propuesto por la OPS.

Con fines de transparencia metodológica, cabe señalar que durante la fase exploratoria se intentó modelar directamente el recuento continuo de casos de dengue, evaluando los periodos de mayor intensidad epidémica mediante datos filtrados y truncados. Dicha aproximación fue descartada al no alcanzar la robustez estadística: el modelo basado en la distribución binomial negativa truncada presentó desviaciones severas y desalineación en los cuantiles de los residuales simulados vía `DHARMa`, incluso tras explorar diferentes transformaciones de escala. Por esta razón, se priorizó la especificación binaria del evento de brote, que ofrece estabilidad numérica, control de errores y una interpretación directa del riesgo de transición hacia fases epidémicas. Futuros trabajos interesados en el modelado continuo durante fases epidémicas agudas pueden retomar esta línea partiendo de las implementaciones alternativas disponibles en el repositorio del proyecto, pero deberán enfrentar el desafío de estabilizar numéricamente la componente de conteo sobre paneles de alta variabilidad departamental.

8. Limitaciones

Este estudio tiene varias limitaciones que condicionan la interpretación de los resultados. Primero, el diseño es observacional y ecológico, con datos agregados a escala departamental y semanal; por tanto, las asociaciones estimadas no identifican relaciones causales ni efectos a nivel individual. Además, la variable de desenlace clasifica cada semana como brote o no brote a partir del percentil 75 interno de cada departamento, un umbral operativo útil para comparar

riesgo relativo pero no validado contra un estándar clínico o de salud pública. Como el umbral se calcula sobre toda la serie 2014–2022, no captura cambios en la definición de brote ni en la capacidad de vigilancia a lo largo del tiempo.

Segundo, la serie de casos proviene de OpenDengue y puede estar afectada por subregistro, cambios en la notificación y heterogeneidad en la calidad del dato entre departamentos. Tampoco se dispone de información sobre serotipo, edad, intervenciones de control vectorial, movilidad poblacional u otras covariables que podrían confundir las asociaciones climáticas. La estructura espacial se limita a un intercepto aleatorio departamental; no se modeló autocorrelación espacial formal ni dependencia entre departamentos vecinos.

Tercero, el panel presentó 36 departamento-semanas sin registro (0,4 % del panel completo de 8.316). La grilla se completó con la función `fill_gaps()` de `tsibble` y los casos se imputaron mediante interpolación lineal dentro de cada departamento con la función `na_interpolation(..., option = "linear")` de `imputeTS`; las brechas residuales de temperatura y lluvia también se interpolaron linealmente dentro del departamento. Este procedimiento supone transiciones suaves y datos faltantes no informativos, y no propaga la incertidumbre de imputación a los errores estándar ni a los intervalos de confianza.

Cuarto, la inercia epidémica de la semana anterior absorbe gran parte de la señal explicativa. En un modelo de sensibilidad sin `ln_casos_semana_anterior` (AIC = 3962.7; BIC = 4145.3), el OR de Niño 3.4 fue 5.26 con un intervalo de confianza extremadamente amplio (0.011–2576), mientras que la lluvia y la temperatura perdieron significancia ($p = 0.799$ y $p = 0.246$, respectivamente). Esto indica que las asociaciones climáticas estimadas en el modelo principal deben interpretarse condicionadas a la memoria epidemiológica y no como efectos aislados.

Finalmente, el modelo no fue concebido como herramienta de pronóstico. La clasificación binaria del brote descarta la magnitud de la incidencia y la estructura AR(1) de alta persistencia hace que las proyecciones fuera de muestra sean especialmente sensibles a shocks no observados. Futuras extensiones deberían incorporar validación temporal, datos entomológicos y de movilidad, y un análisis espacial explícito para evaluar la dependencia entre departamentos.

9. Reproducibilidad y Disponibilidad de Materiales

Con el fin de facilitar la replicación y la extensión de este análisis, todos los materiales asociados al estudio se encuentran disponibles públicamente bajo licencia MIT en el repositorio de GitHub del proyecto. El repositorio incluye:

- El script de limpieza y construcción del panel (`01-cleaning.R`), que documenta la descarga de los registros epidemiológicos de OpenDengue (Clarke et al., 2025), la extracción de las series climáticas de Open-Meteo (2024).
- El script de modelado (`03-GLMM.R`), que especifica los *Generalized Linear Mixed Models* en `glmmTMB` (Brooks et al., 2017), la construcción de los umbrales departamentales (percentil 75), el cálculo de las variables de inercia epidémica y precipitación acumulada, y los diagnósticos de residuales con `DHARMa` (Hartig, 2022).
- El archivo `main.tex` y la base bibliográfica `references.bib` que generan este documento.
- La base procesada final (`dengue_dataframe.csv` y `Etapas_dengue.csv`), lista para reproducir las estimaciones reportadas en la Tabla 2.

10. Conclusiones

Este estudio demuestra que la probabilidad de que un departamento en Nicaragua detone un brote de dengue responde a una interacción entre la memoria epidemiológica local y choques climáticos exógenos. Al aislar la elevada persistencia del contagio semanal mediante una estructura autorregresiva ($\rho = 0.96$), se evidenció que la precipitación acumulada en tres semanas y la temperatura media actúan como factores ambientales asociados de forma independiente y estadísticamente robusta. En contraste, la anomalía de Niño 3.4 no mostró una asociación independiente robusta una vez controlados la estacionalidad mensual y la tendencia anual.

En términos sustantivos, estos hallazgos aportan evidencia cuantitativa sobre los factores ambientales asociados a la transición hacia fases epidémicas a escala departamental. Dado que la dinámica del dengue se encuentra fuertemente dominada por la inercia semanal de casos, los resultados sugieren que las intervenciones de vigilancia y control podrían beneficiarse de incorporar información sobre anomalías hídricas acumuladas, no como un mecanismo de pronóstico operativo, sino como un criterio adicional para caracterizar el riesgo relativo entre departamentos y semanas.

Declaración de Conflicto de Interés

El autor declara no tener conflicto de interés alguno en relación con este trabajo.

Referencias

Anyamba, A., Chretien, J.-P., Britch, S. C., Soebiyanto, R. P., Small, J. L., Jepsen, R., Forshey, B. M., Sanchez, J. L., Smith, R. D., Harris, R., Tucker, C. J., Karesh, W. B., & Linthicum, K. J. (2019). Global disease outbreaks associated with the 2015–2016 El Niño event. *Scientific Reports*, *9*, 1930. https://doi.org/10.1038/s41598-018-38034-z

Benchimol, E. I., Smeeth, L., Guttmann, A., Harron, K., Moher, D., Petersen, I., Sørensen, H. T., von Elm, E., & Langan, S. M. (2015). The REporting of studies Conducted using Observational Routinely-collected health Data (RECORD) statement. *PLOS Medicine*, *12*(10), e1001885. https://doi.org/10.1371/journal.pmed.1001885

Bhatt, S., Gething, P. W., Brady, O. J., Messina, J. P., Farlow, A. W., Moyes, C. L., Drake, J. M., Brownstein, J. S., Hoen, A. G., Sankoh, O., Myers, M. F., George, D. B., Jaenisch, T., Wint, G. R. W., Simmons, C. P., Scott, T. W., Farrar, J. J., & Hay, S. I. (2013). The global distribution and burden of dengue. *Nature*, *496*(7446), 504-507. https://doi.org/10.1038/nature12060

Bowman, L. R., Runge-Ranzinger, S., & McCall, P. J. (2014). Assessing the relationship between vector indices and dengue transmission: a systematic review of the evidence. *PLOS Neglected Tropical Diseases*, *8*(5), e2848. https://doi.org/10.1371/journal.pntd.0002848

Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time Series Analysis: Forecasting and Control* (5.ª ed.). Wiley.

Brady, O. J., Gething, P. W., Bhatt, S., Messina, J. P., Brownstein, J. S., Hoen, A. G., Moyes, C. L., Farlow, A. W., Scott, T. W., & Hay, S. I. (2012). Refining the global spatial limits of dengue virus transmission by evidence-based consensus. *PLOS Neglected Tropical Diseases*, *6*(8), e1760. https://doi.org/10.1371/journal.pntd.0001760

Breslow, N. E., & Clayton, D. G. (1993). Approximate Inference in Generalized Linear Mixed Models. *Journal of the American Statistical Association*, *88*(421), 9-25. https://doi.org/10.1080/01621459.1993.10594284

Brooks, M. E., Kristensen, K., van Benthem, K. J., Magnusson, A., Berg, C. W., Nielsen, A., Skaug, H. J., Mächler, M., & Bolker, B. M. (2017). glmmTMB balances speed and flexibility among packages for zero-inflated generalized linear mixed modeling. *The R Journal*, *9*(2), 378-400. https://doi.org/10.32614/RJ-2017-066

Clarke, J., Lim, A., Gupte, P. R., Pigott, D. M., van Panhuis, W. G., & Brady, O. J. (2025). OpenDengue: data from the OpenDengue database [Version 1.3]. https://doi.org/10.6084/m9.figshare.24259573

Diggle, P. J., Heagerty, P., Liang, K.-Y., & Zeger, S. L. (2002). *Analysis of Longitudinal Data* (2.ª ed.). Oxford University Press.

Fitzmaurice, G. M., Laird, N. M., & Ware, J. H. (2011). *Applied Longitudinal Analysis* (2.ª ed.). Wiley.

Gordon, A., Kuan, G., Mercado, J. C., Gresh, L., Avilés, W., Balmaseda, A., & Harris, E. (2013). The Nicaraguan Pediatric Dengue Cohort Study: Incidence of inapparent and symptomatic dengue virus infections, 2004–2010. *PLOS Neglected Tropical Diseases*, *7*(9), e2462. https://doi.org/10.1371/journal.pntd.0002462

Hartig, F. (2022). *DHARMa: Residual Diagnostics for Hierarchical (Multi-Level / Mixed) Regression Models* [R package version 0.4.6]. https://CRAN.R-project.org/package=DHARMa

McCullagh, P., & Nelder, J. A. (1989). *Generalized Linear Models* (2.ª ed.). Chapman & Hall.

Mordecai, E. A., Caldwell, J. M., Grossman, M. K., Lippi, C. A., Johnson, L. R., Neira, M., Rohr, J. R., Ryan, S. J., Savage, V., Shocket, M. S., Sippy, R., Stewart Ibarra, A. M., Thomas,

M. B., & Villena, O. (2019). Thermal biology of mosquito-borne disease. *Ecology Letters*, *22*(10), 1690-1708. https://doi.org/10.1111/ele.13335

Mordecai, E. A., Cohen, J. M., Evans, M. V., Gudapati, P., Johnson, L. R., Lippi, C. A., Miazgowicz, K., Murdock, C. C., Rohr, J. R., Ryan, S. J., Savage, V., Shocket, M. S., Stewart Ibarra, A. M., Thomas, M. B., & Weikel, D. P. (2017). Detecting the impact of temperature on transmission of Zika, dengue, and chikungunya using mechanistic models. *PLOS Neglected Tropical Diseases*, *11*(4), e0005568. https://doi.org/10.1371/journal.pntd.0005568

Morin, C. W., Comrie, A. C., & Ernst, K. (2013). Climate and dengue transmission: evidence and implications. *Environmental Health Perspectives*, *121*(11–12), 1264-1272. https://doi.org/10.1289/ehp.1306556

NOAA Climate Prediction Center. (2026). *Weekly OISST v2.1 Niño region sea surface temperature indices* [Accessed: 2026-11-09]. https://www.cpc.ncep.noaa.gov/data/indices/wksst9120.for

Open-Meteo. (2024). Historical Weather API: Past weather data archive [Accessed: 2026-10-05]. https://open-meteo.com/en/docs/historical-weather-api

Organización Panamericana de la Salud. (2002). *Módulos de principios de epidemiología para el control de enfermedades (MOPECE): Módulo 5: Investigación epidemiológica de campo: aplicación al estudio de brotes* (2.ª). https://iris.paho.org/handle/10665.2/40137

Pinheiro, J. C., & Bates, D. M. (2000). *Mixed-Effects Models in S and S-PLUS*. Springer.

Shmueli, G. (2010). To Explain or to Predict? *Statistical Science*, *25*(3), 289-310. https://doi.org/10.1214/10-STS330

Standish, K., Kuan, G., Avilés, W., Balmaseda, A., & Harris, E. (2010). High dengue case capture rate in four years of a cohort study in Nicaragua compared to national surveillance data. *PLOS Neglected Tropical Diseases*, *4*(3), e633. https://doi.org/10.1371/journal.pntd.0000633

Suazo-Laguna, H., Mojica-DÍaz, J., Lopez, M. M., Balmaseda, A., Harris, E., Coloma, J., & Juarez, J. G. (2026). Abundance of the vector *Aedes aegypti* in urban and rural areas in Managua, Nicaragua. *PLOS Neglected Tropical Diseases*, *20*(4), e0014256. https://doi.org/10.1371/journal.pntd.0014256

von Elm, E., Altman, D. G., Egger, M., Pocock, S. J., Gøtzsche, P. C., & Vandenbroucke, J. P. (2007). The Strengthening the Reporting of Observational Studies in Epidemiology (STROBE) statement: guidelines for reporting observational studies. *The Lancet*, *370*(9596), 1453-1457. https://doi.org/10.1016/S0140-6736(07)61602-X

Zuur, A. F., Ieno, E. N., & Elphick, C. S. (2010). A protocol for data exploration to avoid common statistical problems. *Methods in Ecology and Evolution*, *1*(1), 3-14. https://doi.org/10.1111/j.2041-210X.2009.00001.x